KLASIFIKASI KUALITAS UDARA MENGGUNAKAN ALGORITMA LIGHTGBM BERDASARKAN ISPU

Muchamad Dicky Alifiansyah[1], **Ani Dijah Rahajoe**[2], **Eva Yulia Puspaningrum**[3]
[1,2,3] Program Studi Informatika, Fakultas Ilmu Komputer, UPN "Veteran" Jawa Timur
Jl. Raya Rungkut Madya No.1, Gunung Anyar, Surabaya, Jawa Timur 60294
[*]Email: 21081010276@student.upnjatim.ac.id

Abstrak

Udara yang bersih dan berkualitas tentunya menjadi kebutuhan penting bagi seluruh makhluk hidup untuk menunjung kehidupan dan kesejahteraan. Kualitas udara yang buruk dapat memengaruhi kesehatan dan kesejahteraan masyarakat yang ada disekitarnya. Oleh karena itu pentingnya pengawasan kualitas udara pada suatu wilayah untuk mencegah dan mengatasi kualitas udara yang buruk secara dini. Pendekatan Machine Learning mampu mengatasi keterbatasan pemantauan dan pengawasan kualitas udara yang dilakukan melalui pengamatan visual berdasarkan ISPU. Data yang digunakan pada penelitian adalah Data Indeks Standar Pencemaran Udara. Penelitian ini bertujuan untuk melakukan klasifikasi kualitas udara menggunakan Algoritma LightGBM berdasarkan ISPU. LigthGBM merupakan metode Gradient Boosting berbasis pohon keputusan. Model LightGBM dibagi menjadi 3 rasio data yaitu 90:10, 80:20 dan 70:30. Hasil penelitian membuktikan bahwa LightGBM mampu melakukan klasifikasi dengan baik pada ketiga rasio data dengan hasil akurasi diatas 90%. LightGBM dengan rasio data 70:30 merupakan model yang memiliki hasil akurasi tertinggi sebesar 96.01% dibanding 2 model lain. Sementara LightGBM dengan rasio data 90:10 memiliki akurasi sebesar 92.93% dan LightGBM dengan rasio data 80:20 memiliki akurasi sebesar 95.10%.

***Kata kunci**: klasifikasi, LightGBM, ISPU, kualitas udara.*

1. PENDAHULUAN

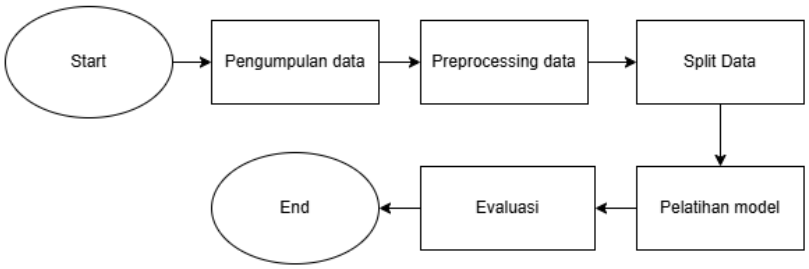
Udara yang bersih dan berkualitas merupakan salah satu kebutuhan untuk menunjang kehidupan. Kualitas udara dapat menjadi standar atau indikator lingkungan yang sehat dan kesejahteraan masyarakat. Semakin meningkatnya aktivitas di berbagai bidang seperti industri, transportasi, dan pembangunan infrastrukur menyebabkan peningkatan polusi udara yang berdampak pada kualitas udara. Menurut WHO (World Health Organization) Polusi udara adalah kandungan yang mencemari dan mengubah karakteristik natural atmosfer, baik dalam bentuk biologis, kimia atau fisika (Hidajat et al., 2023). Udara yang terdampak polusi dapat menurunkan kualitas udara. Kualitas udara yang buruk tentu memengaruhi kehidupan dan kesehatan masyarakat yang ada di sekitarnya.

Jakarta merupakan salah satu kota yang memiliki kualitas udara buruk di Indonesia. Berdasarkan data IQAir pada Awal Januari 2024, Jakarta berada pada posisi ke-15 kota dengan kualitas terburuk di dunia (Kannajmi & Saputra, 2025). Pencemaran udara dapat mengganggu sistem pernafasan dan mengakibatkan berbagai penyakit seperti asma, iritasi mata, sesak napas, meningkatkan resiko kanker paru-paru dan penyakit kronis (Evita Della Ertiana, 2022). Menurut WHO polusi udara bertanggung jawab atas sekitar 7 juta kematian dini pada setiap tahun di seluruh dunia. Perlunya pemantauan dan pengawasan untuk mencegah dan mengatasi kualitas udara yang buruk secara dini. Pemantauan secara manual dengan melihat udara menggunakan kasat mata untuk menentukan kualitas udara memiliki keterbatasan, dimana pengamatan visual secara langsung tidak dapat mengidentifikasi kandungan zat dan gas yang ada. Di Indonesia untuk mengidentifikasi kualitas udara suatu wilayah dilakukan menggunakan ISPU yang mengacu pada Peraturan Menteri Lingkungan Hidup dan Kehutanan nomor 14 tahun 2020 (Permen LHK Nomor 14 Tahun 2020, 2020). Untuk mengatasi keterbatasan pemantauan kualitas udara, pendekatan Machine Learning bisa menjadi solusi untuk melakukan klasifikasi kualitas udara berdasarkan ISPU. Klasifikasi adalah proses kategorisasi data atau objek baru ke sebuah kelas atau label tertentu berdasarkan pola (Nasution et al., 2019). Machine learning memungkinkan sistem untuk belajar dari data ISPU dan menghasilkan model prediktif yang mampu mengklasifikasikan kondisi udara secara otomatis. Salah satu Algoritma yang digunakan untuk menangani klasifikasi adalah Algoritma LightGBM.

Algorima Light Gradient Boosting Machine atau LightGBM adalah salah satu Algoritma Gradient Boosting Decision Tree (GBDT) berbasiskan pohon keputusan (Kurniadi & Larasati, 2022). LightGBM bekerja secara bertahap membangun pohon yang berusaha memperbaiki kesalahan dari pohon sebelumnya. LightGBM memiliki kelebihan dapat melakukan proses komputasi lebih cepat dan meminimalisir penggunaan memori dibandingkan Algoritma GBDT yang lain. Karena LighGBM memiliki teknik utama seperti GOSS, EFB, leaf-wise dan histogram based. Algoritma LightGBM dikenal dengan kemampuan melakukan klasifikasi yang akurat dan stabil (Duran et al., 2024). Penelitian ini bertujuan untuk menganalisa dan mengevaluasi performa Algoritma LightGBM dalam melakukan klasifikasi kualitas udara berdasarkan ISPU. Selain itu penelitian ini diharapkan bisa menjadi pendukung sistem pemantauan kualitas udara otomatis berbasis data dan menjadi literatur dalam bidang atau penelitian sejenis.

2. METODOLOGI

Pada bagian metodologi akan memaparkan proses penelitian dan metode yang digunakan. Penelitian ini memiliki 5 tahapan proses. Mulai dari pengumpulan data hingga evaluasi.



Gambar 1. Metode penelitian

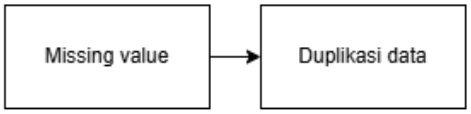
Pada gambar 1 menunjukkan metode penelitian yang akan dilakukan terdiri dari 5 proses. Proses meliputi pengumpulan data, preprocessing data, split data, pelatihan model dan evaluasi. Berikut ini adalah detail dari tiap proses penelitian.

2.1. Pengumpulan Data

Data yang digunakan pada penelitian adalah Indeks Standar Pencemaran Udara (ISPU) Provinsi DKI Jakarta pada tahun 2024. Data diperoleh dari situs satudata Jakarta yang diakses melalui. Data memiliki 13 variabel yang terdiri dari 12 fitur dan 1 label. Data yang digunakan pada penelitian memiliki jumlah 1850 baris data.

2.2. Preprocessing Data

Data yang diperoleh selanjutnya akan dilakukan preprocessing sebelum masuk ke tahap pelatihan model. Preprocessing adalah proses penting dalam tahap pengolahan data yang mengubah data mentah menjadi data siap proses(Setiawan & Efendi, 2025). Preprocessing berfungsi untuk menangani anomali yang ada pada data dan menyiapkan data agar dalam keadaan optimal saat pelatihan karena hal tersebut dapat memengaruhi kinerja model. Preprocessing pada penelitian meliputi pengisian missing value dan penghapusan duplikasi.



Gambar 2. Alur preprocessing data

2.3. Split Data

Split data pada penelitian akan dibagi menjadi 3 rasio data yaitu 90:10, 80:20 dan 70:30. Split data bertujuan untuk membagi proporsi antara data train dan data test. Data hasil split digunakan dalam tahap pelatihan model dan evaluasi. Ketiga rasio akan digunakan untuk melihat dan membandingkan performa dari model LightGBM.

2.4. Pelatihan model

Pada pelatihan model akan dilakukan proses training pada data yang telah dilakukan preprocessing. Pada penelitian ini pelatihan model akan dilakukan dengan menerapkan Algoritma LightGBM sebagai klasifikasi. Algoritma LightGBM melatih model menggunakan data train hasil dari split data. Artinya pelatihan model menggunakan LightGBM akan mengeksekusi data train sebesar 90%, 80% dan 70%.

2.5. Evaluasi

Evaluasi model dilakukan untuk mengukur kinerja dan performa model dalam melakukan klasifikasi. Pada penelitian ini evaluasi dilakukan dengan classification report dan confusion matrix. Classification report melakukan evaluasi model dengan menganalisa matriks evaluasi seperti accuracy, precision, recall dan f1-score. Confusion matrix bertujuan untuk melakukan evaluasi pada performa model dalam melakukan klasifikasi berdasarkan label aktual dan label prediksi.

3. HASIL DAN PEMBAHASAN

Pada bagian hasil dan pembahasan akan dilakukan implementasi dari metodologi. Proses pengumpulan data, preprocessing, split data, pelatihan model dan evaluasi akan diuraikan pada bagian ini. Berikut adalah uraian dari proses penelitian

3.1. Pengumpulan Data

Data yang digunakan adalah data Indeks Standar Pencemaran Udara Provinsi DKI Jakarta. Data diperoleh dari situs satudata Jakarta. Data memiliki 13 variabel yaitu periode data, bulan, tanggal, stasiun, pm10, pm2.5, sulfur dioksida (CO2), karbon monoksida (CO), ozon (O3), nitrogen dioksida (NO2), max, parameter pencemar kritis (critical) dan kategori. Data memiliki jumlah 1850 baris data.

Tabel 1. Data Indeks Standar Pencemaran Udara

periode data	bulan	tanggal	stasiun	pm10	pm2.5	CO2	CO	O3	NO2	max	critical	kategori
202401	1	31	Jagakarsa	37	47	7	26	17	17	47	pm2.5	baik
202402	2	3	Bunderan HI	33	51	48	10	20	22	51	pm2.5	sedang
202402	2	29	Jagakarsa	54	13	50	12	12	41	54	pm10	sedang
202403	3	5	Kebon Jeruk	18	38	21	14	46	6	46	O3	baik
...	...	...	...	...	...	...	...	...	...	...	...	...

3.2. Preprocessing Data

Preprocessing bertujuan untuk memperbaiki kualitas data sebelum masuk tahap pelatihan. Pada penelitian akan menggunakan 2 tahap preprocessing. Berikut ini adalah preprocessing yang digunakan pada penelitian.

3.2.1. Missing value

Missing value berfungsi untuk mengidentifikasi adanya nilai kosong pada data. Nilai kosong yang ada nantinya akan diisi dengan nilai rata-rata atau mean. Pada penelitian terdapat missing value yang teridentifikasi.

	0
pm_sepuluh	106
pm_duakomalima	14
sulfur_dioksida	3
karbon_monoksida	6
ozon	3
nitrogen_dioksida	20
kategori	0

Gambar 3. Missing value pada data

Pada gambar 3 terlihat adanya missing value pada beberapa fitur data. Pada fitur pm_sepuluh terdapat 106 missing value, pm_duakomalima terdapat 14 missing value, sulfur_dioksida terdapat 3 missing value, karbon_monoksida terdapat 6 missing value, ozon terdapat 3 missing value dan nitrogen_dioksida terdapat 20 missing value. Fitur-fitur yang mengalami missing value akan diganti dengan nilai rata-rata dari fitur tersebut.

3.2.2. Duplikasi data

Duplikasi data berfungsi untuk mengidentifikasi adanya baris yang sama persis dengan baris lain pada dataset. Duplikasi dapat memengaruhi kinerja model(Hidayatullah et al., 2014), maka dari itu perlu penanganan untuk menghapus duplikasi pada data.

```
np.int64(10)
```

Gambar 4. Duplikasi pada data

Pada gambar 4 terlihat adanya duplikasi pada data sebesar 10 duplikasi. Artinya data mengalami duplikasi di 20 baris data. Baris satu memiliki nilai yang sama persis dengan sama lain. Untuk menangani data yang terindetifikasi duplikasi akan dihapus salah satu baris dan baris lainnya akan dipertahankan.

3.3. Split Data

Setelah melalui preprocessing data masuk ke bagian split data. Split data bertujuan untuk membagi data menjadi data train dan data test. Pada penelitian ini split data menerapkan 3 rasio yaitu 90:10, 80:20 dan 70:30. Data train akan digunakan untuk pelatihan model. Sementara data test akan digunakan untuk mengevaluasi model.

Tabel 2. Distribusi Split data

Split data	Data train	Data test
90:10	1650	184
80:20	1467	367
70:30	1283	551

Pada tabel 2 adalah distribusi dari ketiga rasio split data yaitu 90:10,80:20 dan 70:30. Pada rasio 90:10, data train memiliki jumlah 1650 data dan data test memiliki jumlah 184 data. Pada rasio 80:20, data train memiliki jumlah 1467 data dan data test memiliki jumlah 367 data. Pada rasio 70:30, data train memiliki jumlah 1283 data dan data test memiliki jumlah 551 data.

3.4. Pelatihan Model

Pelatihan model pada penelitian menerapkan Algoritma LightGBM untuk melakukan klasifikasi. LightGBM akan dilatih dengan 3 rasio data train untuk melihat performa dalam

menghadapi variasi data. LightGBM akan menggunakan hyperparameter default dari library. Model akan dilatih dengan set dasar dari LightGBM.

3.5. Evaluasi

Setelah dilakukan proses pelatihan model, selanjutnya model akan memasuki tahap evaluasi. Evaluasi bertujuan untuk menganalisa performa model dalam melakukan klasifikasi terhadap data yang belum pernah dilihat sebelumnya atau lebih tepatnya pada data test. Evaluasi pada penelitian menggunakan dua pendekatan yaitu classification report dan confusion matrix. Berikut adalah detail dari evaluasi model.

3.5.1. Classification report

Evaluasi classification report merupakan evaluasi berdasarkan matriks evaluasi. Matriks evaluasi yang digunakan adalah accuracy, precision, recall dan f1-score. Pada penelitian ini evaluasi akan dilakukan pada model LightGBM dengan 3 rasio data. Evaluasi ditujukan untuk melihat hasil matriks evaluasi ketiga model tersebut.

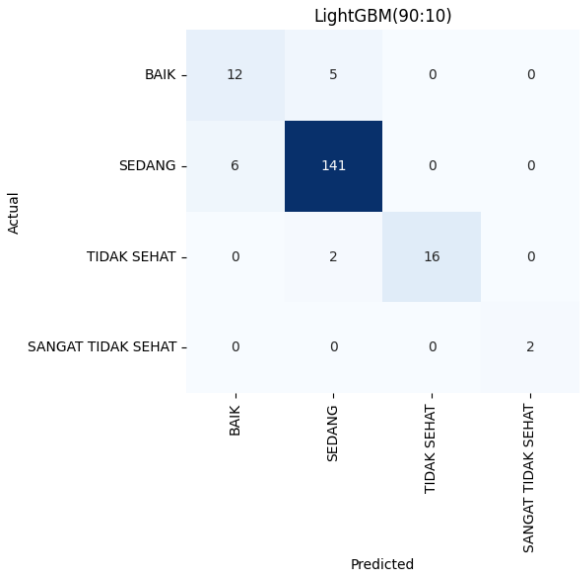
Tabel 3. Hasil classification report model LightGBM

Model	Split data	accuracy	precision	recall	f1-score
1	90:10	0.9293	0.9048	0.8885	0.8885
2	80:20	0.9510	0.9281	0.9193	0.9231
3	70:30	0.9601	0.9377	0.9028	0.9182

Pada tabel 3 menunjukkan hasil matriks evaluasi dari ke 3 model. Model 1 dengan split data 90:10 menghasilkan akurasi sebesar 0.9293, precision sebesar 0.9048, recall sebesar 0.8885 dan f1-score sebesar 0.8885. Model 2 dengan split data 80:20 menghasilkan akurasi 0.9510, precision sebesar 0.9281, recall sebesar 0.9193 dan f1-score sebesar 0.9231. Model 3 dengan split data 70:30 menghasilkan akurasi sebesar 0.9601, precision sebesar 0.9377, recall sebesar 0.9028 dan f1-score sebesar 0.9182.

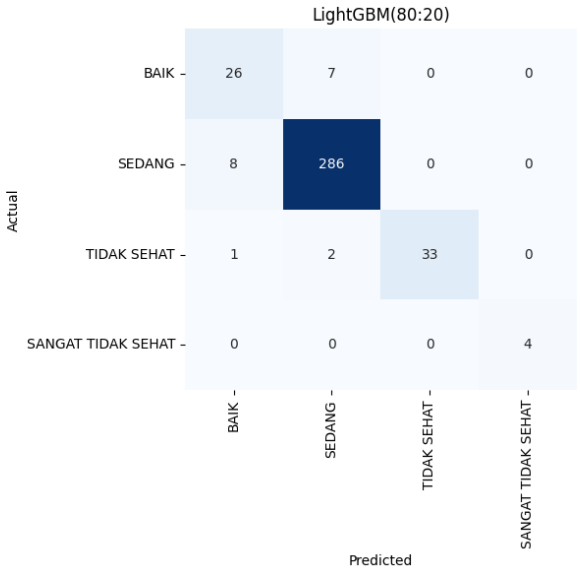
3.5.2. Confusion matrix

Confusion matrix adalah tabel yang menginformasikan hasil prediksi jumlah data uji yang benar dan jumlah data uji yang salah(Normawati & Prayogi, 2021). Confusion matrix merupakan evaluasi performa model dalam membedakan antar kelas atau label. Confusion matrix membantu untuk melihat performa model dalam melakukan klasifikasi. Pada penelilitian ini ketiga model yang telah dilatih akan dievaluasi dengan confusion matrix untuk melihat performa dari tiap model.



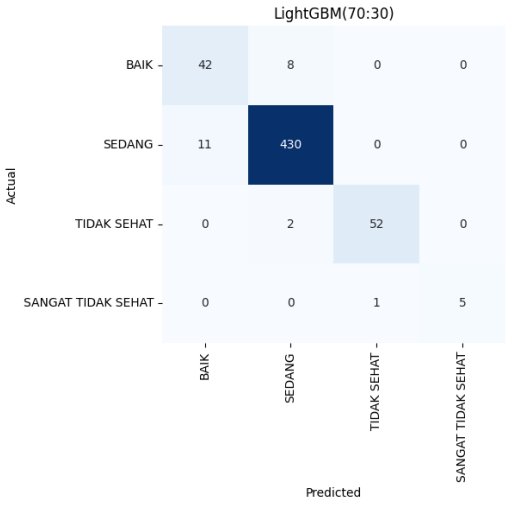
Gambar 5. Confusion matrix model (90:10)

Pada gambar 5 merupakan hasil confusion matrix dari model LightGBM dengan rasio data 90:10. Model mampu melakukan prediksi dengan baik pada tiap kelas. Pada kelas “baik” model memprediksi dengan benar sebesar 12 dan ada kesalahan prediksi sebesar 5 data. Pada kelas “sedang” model memprediksi dengan benar sebesar 141 data dan ada kesalahan prediksi sebesar 6 data. Pada kelas “tidak sehat” model memprediksi dengan benar sebesar 16 data dan ada kesalahan prediksi sebesar 2 data. Pada kelas “sangat tidak sehat” model memprediksi dengan benar sebesar 2 data dan tidak ada kesalahan prediksi.



Gambar 6. Confusion matrix model (80:20)

Pada gambar 6 merupakan hasil confusion matrix dari model LightGBM dengan rasio data 80:20. Model mampu melakukan prediksi dengan baik pada tiap kelas. Pada kelas “baik” model memprediksi dengan benar sebesar 26 dan ada kesalahan prediksi sebesar 7 data. Pada kelas “sedang” model memprediksi dengan benar sebesar 286 data dan ada kesalahan prediksi sebesar 8 data. Pada kelas “tidak sehat” model memprediksi dengan benar sebesar 33 data dan ada kesalahan prediksi sebesar 2 dan 1 data. Pada kelas “sangat tidak sehat” model memprediksi dengan benar sebesar 4 data dan tidak ada kesalahan prediksi.

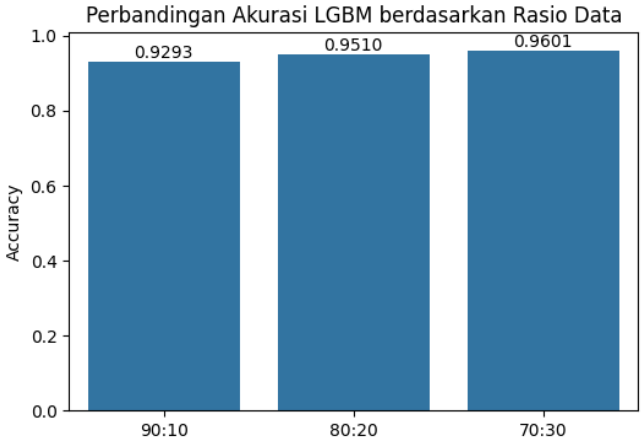


Gambar 7. Confusion matrix model (70:30)

Pada gambar 7 merupakan hasil confusion matrix dari model LightGBM dengan rasio data 70:30. Model mampu melakukan prediksi dengan baik pada tiap kelas. Pada kelas "baik" model memprediksi dengan benar sebesar 42 dan ada kesalahan prediksi sebesar 8 data. Pada kelas "sedang" model memprediksi dengan benar sebesar 430 data dan ada kesalahan prediksi sebesar 11 data. Pada kelas "tidak sehat" model memprediksi dengan benar sebesar 52 data dan ada kesalahan prediksi sebesar 2 data. Pada kelas "sangat tidak sehat" model memprediksi dengan benar sebesar 5 data dan ada kesalahan prediksi sebesar 1 data.

3.6. Analisa dan perbandingan model

Setelah melakukan evaluasi pada beberapa model LightGBM dilakukan analisa dan perbandingan model. Analisa dan perbandingan model dilakukan untuk melihat performa model terbaik diantara 3 model yang telah dilatih. Perbandingan 3 model berdasarkan hasil matriks "accuracy" yang didapatkan dari evaluasi.



Gambar 8. Perbadingan akurasi model berdasarkan rasio data

Pada gambar 8 menunjukkan perbandingan dari ketiga model LightGBM. Perbandingan berdasarkan pada matriks accuracy dan rasio data. Model dengan rasio data 90:10 menghasilkan akurasi 0.9293. Model dengan rasio data 80:20 menghasilkan akurasi 0.9510. Model dengan rasio data 70:30 menghasilkan akurasi 0.9601. Jika dibandingkan dari ketiga model berdasarkan hasil akurasi, maka model LightGBM dengan rasio data 70:30 adalah yang terbaik daripada 2 model yang lain. Perbedaan akurasi model sekitar 0.0091 dari model dengan rasio data 80:20, sementara pada rasio data 90:10 perbedaan akurasi model sekitar 0.0308.

4. KESIMPULAN

Beberapa kesimpulan yang dapat ditarik berdasarkan hasil dan pembahasan dari penelitian ini adalah sebagai berikut:

(1) Penelitian menerapkan 2 teknik preprocessing yaitu menangani missing value dan menghapus duplikasi data.
(2) Rasio data yang digunakan pada penelitian dibagi menjadi 3 yaitu 90:10, 80:20 dan 70:30.
(3) Evaluasi model pada penelitian menggunakan classification report dan confusion matrix. Classification report bertujuan untuk melakukan evaluasi berdasarkan matriks accuracy, precision, recall dan f1-score. Confusion matrix bertujuan untuk melakukan evaluasi performa model dalam melakukan klasifikasi berdasarkan label aktual dan label prediksi.
(4) Dari hasil analisa dan perbandingan model setelah evaluasi didapatkan bahwa model dengan rasio 70:30 merupakan model LigthGBM dengan hasil akurasi paling tinggi sebesar 0.9601 atau 96% dibandingkan 2 model lain.
(5) Model LightGBM dengan rasio data 90:10 memiliki hasil akurasi sebesar 0.9293 atau 92%, menjadi yang paling rendah dibandingkan 2 model lain

(6) Model LightGBM dengan rasio data 80:20 memiliki hasil akurasi sebesar 0.9510 atau 95%, menjadi model yang lebih baik dari rasio data 90:10 namun tidak lebih baik dari model dengan rasio data 70:30.
(7) Ketiga model LightGBM memiliki hasil akurasi yang baik dengan nilai akurasi diatas 90%.
(8) Dari penelitian membuktikan bahwa LightGBM memiliki performa yang baik dalam melakukan klasifikasi, khususnya klasifikasi kualitas udara berdasarkan ISPU

DAFTAR PUSTAKA

Duran, F., Wijaya, F., Hulu, Y. R., Harahap, M., & Prabowo, A. (2024). Perbandingan Kinerja Algoritma Random Forest Classifier Dan Lightgbm Classifier Untuk Prediksi Penyakit Jantung. *Data Sciences Indonesia (DSI)*, *3*(2), 98–103. https://doi.org/10.47709/dsi.v3i2.3831

Evita Della Ertiana. (2022). Dampak Pencemaran Udara terhadap Kesehatan Masyarakat : Literatur Review. *Jurnal Ilmiah Permas: Jurnal Ilmiah STIKES Kendal*, *12*(2), 75–82. https://journal2.stikeskendal.ac.id/index.php/PSKM/article/view/1979/1260

Hidajat, D., Febry Gilang Tilana, & I Gusti Bagus Surya Ari Kusuma. (2023). Dampak Polusi Udara terhadap Kesehatan Kulit. *Unram Medical Journal*, *12*(4). https://doi.org/10.29303/jku.v12i4.1021

Hidayatullah, A. F., Prasetyo, A. D., Sari, D. P., & Pratiwi, I. (2014). Analisis Kualitas Data dan Klasifikasi Data Pasien Kanker. *Seminar Nasional Informatika Medis*, 38–47. https://archive.ics.uci.edu.

Kannajmi, A. R., & Saputra, D. (2025). Penentuan Model Algoritma Klasifikasi Terbaik Untuk Klasifikasi Kualitas Udara Di Jakarta 2023. *Jurnal Informatika Dan Teknik Elektro Terapan*, *13*(1). https://doi.org/10.23960/jitet.v13i1.5664

Kurniadi, F. I., & Larasati, P. D. (2022). Light Gradient Boosting Machine untuk Deteksi Penyakit Stroke. *Jurnal SISKOM-KB (Sistem Komputer Dan Kecerdasan Buatan)*, *6*(1), 67–72. https://doi.org/10.47970/siskom-kb.v6i1.328

Nasution, D. A., Khotimah, H. H., & Chamidah, N. (2019). Perbandingan Normalisasi Data untuk Klasifikasi Wine Menggunakan Algoritma K-NN. *Computer Engineering, Science and System Journal*, *4*(1), 78. https://doi.org/10.24114/cess.v4i1.11458

Normawati, D., & Prayogi, S. A. (2021). Implementasi Naïve Bayes Classifier Dan Confusion Matrix Pada Analisis Sentimen Berbasis Teks Pada Twitter. *Jurnal Sains Komputer & Informatika (J-SAKTI*, *5*(2), 697–711.

Permen LHK Nomor 14 Tahun 2020, Permen LHK Nomor 14 Tahun 2020 Tentang Indeks Standar Pencemar Udara (ISPU) 1 (2020). https://jdih.menlhk.go.id/new2/uploads/files/P_14_2020_ISPU_menlhk_07302020074834.pdf

Setiawan, M. A., & Efendi, M. H. (2025). *Pengaruh Teknik Preprocessing terhadap Kinerja Model Explainable Boosting Machine (EBM) untuk Prediksi Serangan Jantung*. *8*(2), 317–326.