Jurnal Algoritma
E-ISSN: 2302-7339 | P-ISSN: 1412-3622
INSTITUT TEKNOLOGI GARUT

https://jurnal.itg.ac.id/index.php/algoritma
DOI: 10.33364/algoritma/v.22-2.2971

Klasifikasi Indeks Standar Pencemaran Udara Menggunakan Algoritma Catboost Dengan Teknik *Balancing* Data *Random UnderSampling*

Aldy Aditiya[1*], Fajri Rakhmat Umbara[2], Puspita Nurul Sabrina[3]
[1,2,3]Universitas Jenderal Achmad Yani, Indonesia

***email:** aldyaditiya57@gmail.com

Info Artikel
Dikirim: 2 Oktober 2025
Diterima: 6 November 2025
Diterbitkan: 30 November 2025

Kata kunci:
Catboost;
Indeks Standar Pencemar Udara (ISPU);
Klasifikasi;
Kualitas Udara;
Random UnderSampling.

ABSTRAK

Kualitas udara merupakan faktor penting yang memengaruhi kesehatan masyarakat dan lingkungan. Indeks Standar Pencemar Udara digunakan sebagai indikator untuk mengukur tingkat pencemaran udara di suatu wilayah. Tantangan utama dalam proses klasifikasi kualitas udara adalah adanya ketidakseimbangan data yang dapat memengaruhi hasil pemodelan. Penelitian ini bertujuan untuk menganalisis performa algoritma Categorical Boosting (CatBoost) dalam klasifikasi ISPU dengan penerapan teknik *Random* Under sampling untuk mengatasi ketidakseimbangan kelas. Dataset yang digunakan diperoleh dari pemantauan kualitas udara DKI Jakarta periode 2020–2024 dengan jumlah 5.386 record dan 12 atribut. Tahapan penelitian meliputi pengumpulan data, data cleaning, transformasi data, balancing data, feature selection menggunakan *Recursive Feature Elimination* (RFE), pemodelan dengan CatBoost, serta evaluasi model menggunakan confusion matrix. Hasil feature selection menunjukkan lima fitur utama yang paling berpengaruh, yaitu PM10, PM2.5, SO_2, NO_2, dan max. Model CatBoost yang dibangun dengan parameter terbaik menghasilkan akurasi sebesar 98 persen, presisi 100 persen, *recall* 98,91 persen, dan F1-*score* 99,44 persen. Dengan demikian, penerapan CatBoost dan teknik *Random* Under sampling terbukti efektif dalam meningkatkan performa klasifikasi ISPU. Hasil penelitian ini diharapkan dapat digunakan sebagai sistem pendukung keputusan dalam upaya mitigasi dampak polusi udara di DKI Jakarta.

1 PENDAHULUAN

Kualitas udara merupakan salah satu indikator penting dalam menentukan tingkat kesehatan lingkungan dan kualitas hidup masyarakat. Indeks Standar Pencemaran Udara (ISPU) menjadi alat yang digunakan untuk memberikan gambaran tentang kondisi kualitas udara di suatu wilayah. Pada tahun 2020, Kementerian Lingkungan Hidup dan Kehutanan (KLHK) mengeluarkan Peraturan Menteri Lingkungan Hidup dan Kehutanan Nomor 14 Tahun 2020 tentang Perhitungan dan Pelaporan serta Informasi Indeks Standar Pencemar Udara yang menyebutkan bahwa perhitungan ISPU dilakukan pada enam (6) parameter, yakni PM_{10}, $PM_{2.5}$, NO_2, SO_2, CO, dan O_3.Kategori nilai Rentang ISPU untuk kualitas udara, sesuai dengan ketetapan pemerintah, diantaranya kualitas udara dengan kategori Baik, Sedang, Tidak Sehat, Sangat Tidak Sehat, dan Berbahaya[1]. Penerapan klasifikasi ISPU membutuhkan metode yang dapat menganalisis dan mengidentifikasi pola data dari sensor yang mengukur tingkat polutan udara. Salah satu metode yang umum digunakan adalah pembelajaran mesin (machine learning)[2].Pada penelitian sebelumnya,klasifikasi kualitas udara di Tanggerang Selatan dengan penerapan algoritma Naive Bayes Menghasilkan nilai akurasi mencapai 79.38%[1]. Kemudian pada

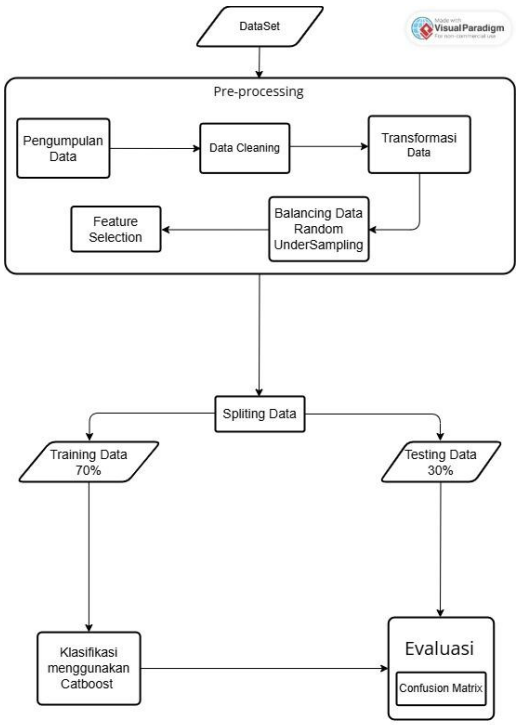
penelitian kedua menggunakan algoritma XGBoost dan SMOTE untuk klasifikasi Indeks Standar Pencemaran Udara menujukan hasil akurasi yang diperoleh dengan penerapan balancing data SMOTE menghasilkan akurasi 99,63 %[2].

Penerapan algoritma klasifikasi konvensional sering kali menemui tantangan, terutama dalam menghadapi kompleksitas data yang sangat bervariasi[3]. CatBoost, sebagai algoritma pembelajaran mesin berbasis *Gradient Boosting*, telah terbukti efektif dalam menangani data dengan berbagai fitur kategori dan kompleksitas[4]. CatBoost merupakan algoritma yang memiliki akurasi dan performa yang tertinggi kemudian disusul XGBoost dan yang paling rendah yaitu algoritma AdaBoost.Namun akurasi dan performanya masih kurang dan perlu ditingkatkan lagi dengan penggunaan berbagai macam metode[5]. Untuk mengatasi masalah ketidakseimbangan data, teknik seperti *Random* Undersampling merupakan pendekatan sederhana namun cukup efektif, yaitu dengan cara mengurangi jumlah sampel dari kelas mayoritas secara acak, sehingga distribusi data menjadi lebih seimbang untuk proses pelatihan model[6].

Penelitian ini berfokus pada performa algoritma CatBoost dengan teknik balancing data *Random* Undersampling dalam mengklasifikasikan Indeks Standar Pencemaran Udara (ISPU) berdasarkan data kualitas udara yang memiliki distribusi kelas tidak seimbang. Hasil dari penelitian ini diharapkan dapat memberikan pemahaman empiris mengenai efektivitas kombinasi metode pembelajaran mesin dan teknik penyeimbangan data dalam meningkatkan akurasi klasifikasi pada data lingkungan yang tidak seimbang, serta mendukung langkah-langkah mitigasi dampak polusi udara terhadap kesejahteraan masyarakat.

2 METODE PENELITIAN

Penelitian yang dilakukan oleh penulis terdiri dari beberapa tahap yang dirancang secara sistematis. Berikut adalah alur metode penelitian yang dilakukan untuk Klasifikasi Indeks Standar Pencemaran Udara Menggunakan Algoritma CatBoost dengan Teknik *Balancing* Data *Random UnderSampling* yang ditunjukkan pada Gambar 1.



Gambar 1. Metode Penelitian

Tahap pertama adalah pengumpulan data, yaitu pengambilan data pencemaran udara DKI Jakarta pada periode tahun 2020 hingga 2024 yang diperoleh dari situs resmi https://satudata.jakarta.go.id/ . Setelah dilakukan pengumpulan data, seluruh data digabungkan menjadi satu kesatuan melalui proses penggabungan beberapa

kumpulan dataset untuk mendapatkan data yang lengkap. Tahap berikutnya adalah data cleaning yang bertujuan untuk memperbaiki kesalahan, menghapus duplikasi, dan menghilangkan parameter yang tidak relevan dalam proses klasifikasi. Proses ini mencakup pengecekan terhadap nilai yang hilang (missing values) serta memastikan bahwa data yang digunakan valid. Pada dataset yang digunakan terdapat data yang bernilai "–" yang perlu dibersihkan agar tidak mengganggu proses analisis[7]. Selanjutnya dilakukan transformasi data yang bertujuan untuk mempermudah pengolahan data sehingga menghasilkan data yang siap digunakan dalam proses data mining[8]. Pada tahap ini, parameter kategori yang awalnya berupa tipe string diubah menjadi tipe data numerik[2]. Transformasi ini membantu sistem dalam memahami data secara lebih efisien sebelum proses analisis dilakukan. Tahapan selanjutnya adalah balancing data, yaitu penyeimbangan distribusi data dengan menggunakan teknik *Random UnderSampling*. Teknik ini merupakan metode yang sederhana namun cukup efektif untuk menangani masalah ketidakseimbangan kelas dengan cara mengurangi jumlah sampel dari kelas mayoritas secara acak, sehingga distribusi data menjadi lebih seimbang untuk proses pelatihan model[9]. Tujuan utama dari *Random UnderSampling* adalah menyamakan distribusi jumlah data antara kelas mayoritas dan minoritas agar model machine learning tidak lebih fokus pada kelas yang dominan[10]. Tahap berikutnya adalah feature selection. Pada tahap ini, penulis melakukan pemilihan subset fitur yang paling relevan dari dataset yang ada. Dalam pembuatan model prediktif, variabel target atau dependen harus dihilangkan dari dataset karena variabel tersebut merupakan target yang akan diprediksi oleh model. Feature selection dilakukan untuk mengurangi dampak dimensi pada kumpulan data melalui pencarian subkumpulan fitur yang mampu mendefinisikan data secara efisien. Dalam penelitian ini digunakan metode *Recursive Feature Elimination* (RFE), yaitu teknik otomatis yang bekerja dengan cara menghapus fitur yang paling tidak penting secara berulang hingga diperoleh kombinasi fitur yang menghasilkan kinerja model klasifikasi terbaik[11]. Tahap selanjutnya adalah klasifikasi menggunakan algoritma CatBoost. Pada tahap ini dilakukan proses pembangunan model CatBoost dengan pengaturan beberapa parameter yang telah ditentukan melalui serangkaian eksperimen untuk menghasilkan klasifikasi yang optimal. CatBoost menggunakan struktur pohon simetris untuk mencapai kecepatan prediksi yang tinggi[12]. Selain itu, algoritma ini mampu menangani data kategorikal secara otomatis dengan memanfaatkan metode statistik, serta dapat mencegah overfitting melalui optimisasi berbagai parameter input dan pengabaian karakteristik kategori selama proses pengolahan data[13]. Tahap terakhir adalah evaluasi model, yang dilakukan setelah proses pemodelan menggunakan CatBoost. Evaluasi dilakukan dengan menggunakan *Confusion Matrix*, yaitu metode yang digunakan untuk menggambarkan perbandingan antara hasil prediksi model dan kondisi aktual yang sebenarnya. *Confusion Matrix* terdiri atas empat komponen utama, yaitu *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), dan *False Negative* (FN). Komponen-komponen ini memberikan informasi mengenai hasil klasifikasi yang dilakukan oleh sistem dibandingkan dengan hasil klasifikasi yang sebenarnya[14]. Beberapa metrik evaluasi yang digunakan dalam penelitian ini meliputi akurasi, presisi, *recall*, dan F1-*score*, yang digunakan untuk menilai tingkat ketepatan model dalam membedakan kelas saat melakukan prediksi atau klasifikasi. Adapun persamaannya sebagai berikut:

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN} \quad (2)$$

$$Presisi = \frac{TP}{TP+FP} \quad (3)$$

$$Recall = \frac{TP}{TP+FN} \quad (4)$$

$$F1-score = 2 \times \frac{Presisi+Recall}{Presisi+Recall} \quad (5)$$

Dimana untuk nilai dari *TP,TN,FP,dan FN* pada persamaan diatas adalah :

1. TP*(True Positive)* merupakan jumlah observasi yang benar – benar masuk ke dalam kelas positif
2. TN*(True Negative)* merupakan jumlah observasi yang benar-benar termasuk ke dalam kelas negatif
3. FN *(False Positive)* merupakan jumlah observasi yang diprediksi sebagai bagian dari kelas positif oleh model, tetapi sebenarnya observasi tersebut termasuk dalam kelas negatif.

3 HASIL DAN PEMBAHASAN

3.1 Pengumpulan Data

Dataset yang digunakan dalam penelitian ini adalah Indeks Standar Pencemar Udara (ISPU) Gabungan yang diperoleh dari hasil pemantauan kualitas udara di beberapa stasiun pengukuran di wilayah DKI Jakarta. Dataset yang dikumpulkan oleh penulis terdiri atas 5.385 record data dengan 12 atribut yang merepresentasikan kondisi kualitas udara pada periode tertentu.Setiap record memuat informasi mengenai periode data, tanggal pencatatan, nama stasiun pemantau, serta konsentrasi beberapa polutan utama, yaitu PM_{10}, $PM_{2.5}$, SO_2 (sulfur dioksida), CO_2 (karbon monoksida), O_3 (ozon), dan NO_2 (nitrogen dioksida). Selain itu, terdapat pula atribut max yang menunjukkan nilai polutan tertinggi pada waktu tertentu, critical yang menandai jenis polutan dominan, serta category yang mengklasifikasikan kualitas udara ke dalam lima kategori, yaitu Baik, Sedang, Tidak Sehat, Sangat Tidak Sehat, dan Berbahaya.Seperti ditunjukkan pada Gambar 2, tampilan awal dataset menampilkan data mentah yang akan digunakan dalam proses analisis dan pengolahan lebih lanjut.

	periode_data	tanggal	stasiun	pm10	pm25	so2	co	o3	no2	max	critical	categori
2	202101	2021-01-22 00:00:00	DKI5 (Kebon Jeruk)	45		21	13	40	15	45	PM10	BAIK
3	202101	2021-01-23 00:00:00	DKI5 (Kebon Jeruk)	80		22	44	44	22	80	PM10	SEDANG
4	202101	2021-01-24 00:00:00	DKI5 (Kebon Jeruk)	27		14	9	29	---	29	CO	BAIK
5	202101	2021-01-25 00:00:00	DKI5 (Kebon Jeruk)	55		19	29	67	13	67	CO	SEDANG
6	202101	2021-01-26 00:00:00	DKI5 (Kebon Jeruk)	57		21	23	36	16	57	PM10	SEDANG
7	202101	2021-01-27 00:00:00	DKI5 (Kebon Jeruk)	15		16	5	20	---	20	CO	BAIK
8	202101	2021-01-28 00:00:00	DKI5 (Kebon Jeruk)	28		19	11	28	---	28	PM10	BAIK
9	202101	2021-01-29 00:00:00	DKI5 (Kebon Jeruk)	30		22	10	32	11	32	CO	BAIK
10	202101	2021-01-30 00:00:00	DKI5 (Kebon Jeruk)	24		17	8	27	10	27	CO	BAIK
11	202101	2021-01-31 00:00:00	DKI5 (Kebon Jeruk)	41		17	19	29	8	41	PM10	BAIK
12	202102	2021-02-01 00:00:00	DKI1 (Bunderan HI)	59	79	21	26	15	31	79	PM25	SEDANG
13	202102	2021-02-02 00:00:00	DKI1 (Bunderan HI)	30	46	21	14	16	24	46	PM25	BAIK
14	202102	2021-02-03 00:00:00	DKI1 (Bunderan HI)	23	33	19	11	14	19	33	PM25	BAIK
15	202102	2021-02-04 00:00:00	DKI1 (Bunderan HI)	36	53	23	14	12	24	53	PM25	SEDANG
16	202102	2021-02-05 00:00:00	DKI1 (Bunderan HI)	29	36	20	14	12	21	36	PM25	BAIK
17	202102	2021-02-06 00:00:00	DKI1 (Bunderan HI)	27	34	21	8	21	15	34	PM25	BAIK
18	202102	2021-02-07 00:00:00	DKI1 (Bunderan HI)	25	23	19	7	19	12	25	PM10	BAIK
19	202102	2021-02-08 00:00:00	DKI1 (Bunderan HI)	24	26	19	10	18	17	26	PM25	BAIK
20	202102	2021-02-09 00:00:00	DKI1 (Bunderan HI)	33	40	22	12	14	22	40	PM25	BAIK
21	202102	2021-02-10 00:00:00	DKI1 (Bunderan HI)	32	38	21	10	12	16	38	PM25	BAIK
22	202102	2021-02-11 00:00:00	DKI1 (Bunderan HI)	26	37	23	13	9	17	37	PM25	BAIK
23	202102	2021-02-12 00:00:00	DKI1 (Bunderan HI)	41	52	26	16	10	16	52	PM25	SEDANG
24	202102	2021-02-13 00:00:00	DKI1 (Bunderan HI)	25	37	20	9	19	16	37	PM25	BAIK
25	202102	2021-02-14 00:00:00	DKI1 (Bunderan HI)	33	47	18	11	19	19	47	PM25	BAIK
26	202102	2021-02-15 00:00:00	DKI1 (Bunderan HI)	34	47	20	13	17	25	47	PM25	BAIK
27	202102	2021-02-16 00:00:00	DKI1 (Bunderan HI)	26	28	18	11	18	26	28	PM25	BAIK

Gambar 2. Dataset Penelitian

3.2 Data Cleaning

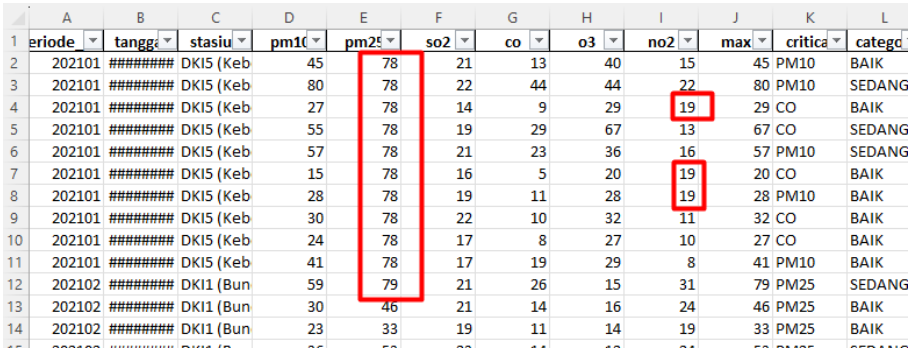
Tahap data cleaning dilakukan dengan tujuan untuk membersihkan dataset dari nilai-nilai yang tidak valid serta menghapus parameter yang tidak diperlukan dalam proses klasifikasi. Fokus utama pada tahap ini adalah menangani data yang memiliki nilai kosong dan nilai “---” agar dataset menjadi lebih konsisten dan siap diolah.

	periode_dat	tang	stasi	pm10	pm25	so2	co	o3	no2	max	critica	catego
2	202101	#####	DKI5 (Ke	45		21	13	40	15	45	PM10	BAIK
3	202101	#####	DKI5 (Ke	80		22	44	44	22	80	PM10	SEDANG
4	202101	#####	DKI5 (Ke	27		14	9	29	---	29	CO	BAIK
5	202101	#####	DKI5 (Ke	55		19	29	67	13	67	CO	SEDANG
6	202101	#####	DKI5 (Ke	57		21	23	36	16	57	PM10	SEDANG
7	202101	#####	DKI5 (Ke	15		16	5	20	---	20	CO	BAIK
8	202101	#####	DKI5 (Ke	28		19	11	28	---	28	PM10	BAIK
9	202101	#####	DKI5 (Ke	30		22	10	32	11	32	CO	BAIK
10	202101	#####	DKI5 (Ke	24		17	8	27	10	27	CO	BAIK
11	202101	#####	DKI5 (Ke	41		17	19	29	8	41	PM10	BAIK
12	202102	#####	DKI1 (Bu	59	79	21	26	15	31	79	PM25	SEDANG
13	202102	#####	DKI1 (Bu	30	46	21	14	16	24	46	PM25	BAIK
14	202102	#####	DKI1 (Bu	23	33	19	11	14	19	33	PM25	BAIK

Gambar 3. Dataset Kotor

Berdasarkan Gambar 3, pada parameter pm2.5 ditemukan nilai kosong pada baris ke-1 hingga baris ke-11, sedangkan pada parameter No2 terdapat nilai “---” pada baris ke-4, ke-7, dan ke-8. Nilai “---” tersebut dikonversi menjadi NaN untuk memudahkan proses perhitungan serta identifikasi data yang hilang (*missing value*).Setelah proses konversi dilakukan, setiap nilai kosong diisi menggunakan median dari masing-masing parameter agar distribusi data tetap stabil dan tidak terjadi bias terhadap hasil analisis. Hasil akhir dari tahap

ini adalah dataset yang telah dibersihkan, terisi secara lengkap, dan siap digunakan pada tahap analisis maupun pemodelan berikutnya.



	A	B	C	D	E	F	G	H	I	J	K	L
1	eriode_	tangg	stasiu	pm10	pm25	so2	co	o3	no2	max	critica	catego
2	202101	########	DKI5 (Keb	45	78	21	13	40	15	45	PM10	BAIK
3	202101	########	DKI5 (Keb	80	78	22	44	44	22	80	PM10	SEDANG
4	202101	########	DKI5 (Keb	27	78	14	9	29	19	29	CO	BAIK
5	202101	########	DKI5 (Keb	55	78	19	29	67	13	67	CO	SEDANG
6	202101	########	DKI5 (Keb	57	78	21	23	36	16	57	PM10	SEDANG
7	202101	########	DKI5 (Keb	15	78	16	5	20	19	20	CO	BAIK
8	202101	########	DKI5 (Keb	28	78	19	11	28	19	28	PM10	BAIK
9	202101	########	DKI5 (Keb	30	78	22	10	32	11	32	CO	BAIK
10	202101	########	DKI5 (Keb	24	78	17	8	27	10	27	CO	BAIK
11	202101	########	DKI5 (Keb	41	78	17	19	29	8	41	PM10	BAIK
12	202102	########	DKI1 (Bun	59	79	21	26	15	31	79	PM25	SEDANG
13	202102	########	DKI1 (Bun	30	46	21	14	16	24	46	PM25	BAIK
14	202102	########	DKI1 (Bun	23	33	19	11	14	19	33	PM25	BAIK

Gambar 4 Missing Value Diisi Median

Pada Gambar 5 terlihat bahwa tidak terdapat lagi data dengan nilai "---" karena nilai tersebut telah digantikan menggunakan nilai median dari masing-masing parameter. Parameter $PM_{2.5}$ memiliki nilai median sebesar 78, sedangkan parameter NO_2 memiliki nilai median sebesar 19. Setelah seluruh kolom pada dataset tidak lagi mengandung missing value, dataset tersebut dinyatakan telah bersih dan siap digunakan untuk memasuki tahapan analisis berikutnya.

3.3 Transformasi Data

Tahapan berikutnya adalah transformasi data, yang bertujuan untuk menyiapkan data dalam format yang sesuai agar dapat diolah secara optimal oleh algoritma klasifikasi yang digunakan Pada tahap transformasi data, penulis melakukan proses pengubahan tipe data dari bentuk string menjadi numerik dengan tujuan untuk mempermudah proses pengolahan data dan mempersiapkannya agar siap digunakan dalam tahap data mining[8]. Pada dataset Indeks Standar Pencemar Udara, terdapat beberapa parameter yang perlu melalui proses transformasi tipe data agar dapat diolah secara optimal oleh algoritma klasifikasi yang akan digunakan.

3.1.1 Transformasi data kategori

Pada tahap transformasi data, parameter category yang memiliki beberapa kelas kategori, yaitu Baik, Sedang, dan Tidak Sehat, perlu diubah ke dalam bentuk numerik agar dapat digunakan dalam proses pemodelan dengan algoritma CatBoost. Transformasi ini dilakukan karena algoritma machine learning umumnya hanya dapat memproses data dalam bentuk numerik. Proses transformasi dilakukan menggunakan metode Ordinal Encoding, yaitu metode yang mengubah nilai kategori ke dalam bentuk angka berdasarkan urutan tingkatannya [15]. Dalam penelitian ini, penulis menetapkan urutan nilai sebagai berikut: Baik = 1, Sedang = 2, Tidak Sehat = 3, dan Sangat Tidak Sehat = 4. Metode ini dipilih karena setiap kategori memiliki makna tingkat yang berurutan sesuai dengan kualitas udara dari kondisi baik hingga sangat tidak sehat.

Tabel 1. Transformasi Data Kategori

Kategori	Transformasi Data
Baik	1
Sedang	2
Tidak Sehat	3

3.1.2 Transformasi data *critical*

Pada tahap transformasi data, parameter critical yang berisi data bertipe string seperti pm10, pm2.5, so2, co, o3, dan no2 perlu diubah menjadi bentuk numerik agar dapat digunakan dalam proses pemodelan menggunakan algoritma CatBoost. Transformasi data pada kolom critical ini dilakukan menggunakan metode Label Encoding, karena nilai-nilai pada kolom tersebut tidak memiliki urutan tingkat tertentu dan hanya berfungsi

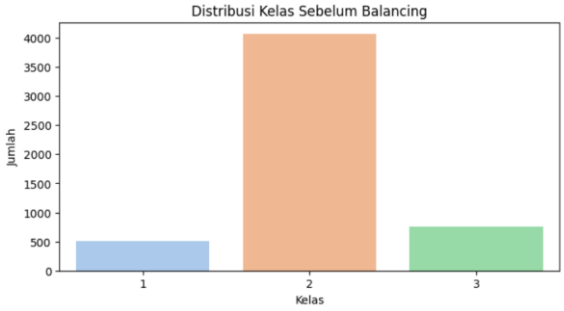
sebagai penanda kategori. Dengan metode ini, setiap kategori seperti pm10, pm2.5, so2, co, o3, dan no2 diberi representasi angka unik sehingga data dapat diolah secara optimal oleh model machine learning.

Tabel 2. Transformasi Data *Critical*

Critical	**Transformasi Data**
NO2	0
PM10	1
PM25	2
SO2	3
CO	4
O3	5

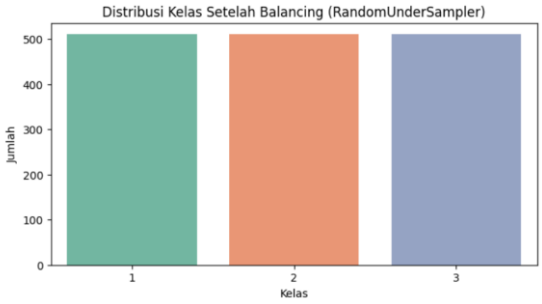
3.4 *Balancing* Data

Pada tahapan ini dilakukan salah satu proses penting dalam pra-pemrosesan data (data *preprocessing*), yaitu balancing data, yang bertujuan untuk mengatasi masalah ketidakseimbangan kelas dalam dataset. Ketidakseimbangan ini terjadi ketika jumlah data pada kelas mayoritas (Sedang) jauh lebih besar dibandingkan dengan kelas minoritas (Baik). Kondisi tersebut dapat menyebabkan bias pada proses pelatihan model, di mana model cenderung lebih fokus mempelajari pola dari kelas mayoritas dan mengabaikan informasi dari kelas minoritas. Untuk mengatasi permasalahan tersebut, penelitian ini menggunakan metode *Random* Undersampling, yaitu salah satu teknik *undersampling* yang bertujuan untuk mengurangi jumlah data pada kelas mayoritas secara acak sehingga distribusi data antar kelas menjadi lebih seimbang. Metode ini dipilih karena memiliki keunggulan dalam hal kesederhanaan, dan efisiensi waktu[16].



Gambar 5 Distribusi kelas sebelum balancing

Pada Gambar 5 terlihat bahwa distribusi kelas pada dataset menunjukkan adanya ketidakseimbangan yang cukup signifikan antara jumlah data pada kategori Baik, Sedang, dan Tidak Sehat. Ketimpangan ini dapat memengaruhi kinerja model klasifikasi, karena model berpotensi lebih fokus pada kelas dengan jumlah data yang lebih besar. Oleh karena itu, untuk mengatasi permasalahan tersebut dilakukan proses balancing data menggunakan metode *Random* Undersampling. Metode ini bekerja dengan cara mengurangi jumlah data pada kelas mayoritas secara acak, sehingga jumlah data pada setiap kelas menjadi seimbang dengan jumlah data pada kelas minoritas.



Gambar 6 Distribusi Kelas Setelah *Balancing*

Proses *under sampling* menghasilkan distribusi akhir yang lebih ideal. Gambar 6 menunjukkan bahwa distribusi kelas telah berada dalam kondisi seimbang, di mana jumlah data untuk masing-masing kelas, yaitu kelas 1 (Baik), kelas 2 (Sedang), dan kelas 3 (Tidak Sehat), memiliki jumlah yang sama, yaitu 510 record. Dengan demikian, dataset yang telah seimbang ini siap digunakan pada tahap pemodelan selanjutnya untuk memastikan hasil klasifikasi yang lebih akurat dan tidak bias terhadap kelas tertentu.

3.5 *Feature Selection*

Pada tahapan feature selection, penulis menggunakan metode *Recursive Feature Elimination* (RFE) dengan memanfaatkan algoritma *Random Forest Classifier* sebagai estimator. Metode RFE bekerja secara iteratif, yaitu dengan melatih model menggunakan seluruh fitur yang tersedia, kemudian menghitung tingkat kepentingan (*feature importance*) dari masing-masing fitur.[17]. Selanjutnya, fitur dengan kontribusi paling rendah akan dieliminasi secara bertahap, hingga tersisa fitur-fitur yang memiliki pengaruh paling signifikan terhadap kinerja model.

	pm10	pm25	so2	no2	max	categori
2	45	78	21	15	45	1
3	27	78	14	19	29	1
4	15	78	16	19	20	1
5	28	78	19	19	28	1
6	30	78	22	11	32	1
7	24	78	17	10	27	1
8	41	78	17	8	41	1

Gambar 7 Hasil *Feature Selection*

Berdasarkan hasil feature selection yang ditunjukkan pada Gambar 7, dengan menggunakan *Recursive Feature Elimination* (RFE), diperoleh lima fitur utama yang paling berpengaruh terhadap variabel target, yaitu pm10, pm2.5, so2, no2, dan max. Mekanisme RFE bekerja dengan melatih model menggunakan seluruh fitur yang tersedia, kemudian secara berulang menghapus fitur dengan kontribusi paling kecil hingga tersisa sejumlah fitur paling signifikan[18].

3.6 *Modelling* Catboost

Pada tahapan ini, penulis menggunakan algoritma CatBoost untuk melakukan klasifikasi Indeks Standar Pencemaran Udara di wilayah DKI Jakarta dengan memanfaatkan data yang telah melalui beberapa tahapan *preprocessing*. Algoritma CatBoost dipilih karena memiliki sejumlah keunggulan, salah satunya adalah kinerjanya yang tinggi pada dataset berukuran kecil hingga menengah. Untuk memperoleh performa terbaik dari model, dilakukan serangkaian eksperimen penyetelan parameter (*parameter tuning*) yang bertujuan untuk meningkatkan kinerja algoritma CatBoost. Beberapa parameter yang digunakan dalam model CatBoost ini dapat dilihat pada Tabel 4.

Tabel 3. Parameter Catboost

Parameter	Kegunaan
iteration	Menentukan jumlah total iterasi yang akan dibangun dalam proses boosting oleh Catboost
learning_rate	Mengatur seberapa besar kontribusi tiap model baru terhadap model akhir.
depth	Menentukan kedalaman maksimum dari pohon keputusan yang dibangun pada setiap iterasi.

3.7 Evaluasi Model

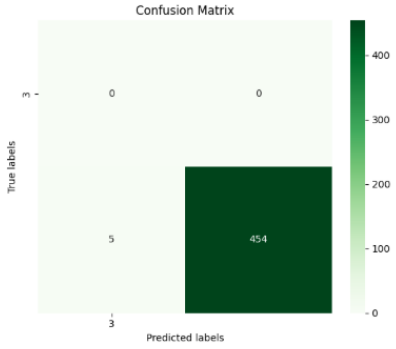
Setelah menyelesaikan tahapan sebelumnya, dilakukan serangkaian eksperimen untuk memperoleh hasil prediksi terbaik berdasarkan data Indeks Standar Pencemaran Udara (ISPU) di wilayah DKI Jakarta. Tujuan

dari eksperimen ini adalah untuk meningkatkan kinerja model CatBoost melalui penyesuaian parameter yang optimal. Hasil dari eksperimen tersebut dapat dilihat pada Tabel 5.

Tabel 4 Hasil eksperimen parameter

Parameter	Percobaan 1	Percobaan 2	Percobaan 3
iteration	100	300	50
learning_rate	0.01	0.01	0.01
depth	10	16	10
Akurasi	93%	98%	92%

Dari Tabel 5 dapat disimpulkan bahwa variasi parameter yang digunakan pada setiap eksperimen memberikan perbedaan tingkat akurasi, meskipun tidak terlalu signifikan. Konfigurasi dengan jumlah iterasi dan kedalaman pohon yang lebih besar mampu menghasilkan akurasi terbaik, yaitu sebesar 98%. Selain itu, setiap eksperimen yang dilakukan juga didasarkan pada penelitian sebelumnya yang menggunakan pendekatan serupa. Pada eksperimen kedua, penelitian difokuskan pada penerapan model CatBoost dengan mengevaluasi tingkat akurasi yang diperoleh. Untuk mengukur kinerja model, digunakan metode evaluasi berbasis confusion matrix, yang berfungsi untuk mengetahui persentase data yang berhasil diprediksi dengan benar sesuai kondisi sebenarnya dibandingkan dengan data yang salah atau tidak sesuai. Hasil confusion matrix dapat dilihat pada Gambar 8.



Gambar 8 *Confusion Matrix*

Berdasarkan confusion matrix pada Gambar 8, terdapat sejumlah nilai yang digunakan untuk mengevaluasi performa model. Dari hasil tersebut diperoleh nilai *True Positive* (TP) sebesar 422, *False Positive* (FP) sebesar 0, *False Negative* (FN) sebesar 37, dan *True Negative* (TN) sebesar 0. Nilai-nilai ini kemudian dimanfaatkan untuk menghitung beberapa metrik evaluasi, yaitu *accuracy*, *precision*, *recall*, dan f1-*score*, yang berfungsi sebagai indikator untuk menilai kinerja model dalam melakukan klasifikasi. Hasil perhitungan dari metrik-metrik tersebut dapat dilihat pada Tabel 6.

Tabel 5 Matrix Evaluasi

Matriks Evaluasi	Skor
Accuracy	98.91%
Precision	100%
Recall	98.91%
F1-Score	99.44%

1. Akurasi dihitung menggunakan persamaan (6).

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN} \quad (6).$$

$$Accuracy = \frac{454+0}{459} = \frac{454}{459} = 0.9891$$

2. Presisi dihitung menggunakan persamaan (7).

$$Presisi = \frac{TP}{TP+FP} \quad (7).$$

$$Presisi = \frac{454}{454+0} = \frac{454}{454} = 1.0$$

3. Recall dihitung menggunakan persamaan (8).

$$Recall = \frac{TP}{TP+FN} \quad (8).$$

$$Recall = \frac{454}{454+5} = \frac{422}{459} = 0.9891$$

4. F1 Score dihitung menggunakan persamaan (9).

$$F1 - score = 2 \times \frac{Presisi+Recall}{Presisi+Recall} \quad (9).$$

$$F1 - score = 2 \times \frac{1.0 \times 0.9891}{1.0+0.9891} = 2 \times \frac{0.9891}{1.9891} = 0.9944$$

4. KESIMPULAN

Penelitian ini dilakukan untuk mengevaluasi performa algoritma CatBoost dalam mengklasifikasikan Indeks Standar Pencemaran Udara di wilayah DKI Jakarta menggunakan dataset awal yang terdiri dari 5.386 record. Fokus utama penelitian ini adalah pada penanganan ketidakseimbangan data menggunakan metode *Random Undersampling* serta penerapan algoritma CatBoost. Setelah melalui serangkaian tahapan *preprocessing*, diperoleh tiga kelas utama dengan masing-masing berjumlah 510 record, yang kemudian dibagi menjadi 70% untuk data pelatihan dan 30% untuk data pengujian. Berdasarkan model pengujian yang dikembangkan, hasil menunjukkan bahwa algoritma CatBoost memiliki performa yang sangat baik dalam mengklasifikasikan data Indeks Standar Pencemaran Udara. Dari serangkaian eksperimen yang dilakukan, diperoleh hasil akurasi terbaik sebesar 98%, presisi sebesar 100%, *recall* sebesar 98,91%, dan F1-*score* sebesar 99,44%. Dengan demikian, dapat disimpulkan bahwa algoritma CatBoost terbukti mampu memberikan hasil prediksi yang sangat baik pada penelitian ini. Tingginya nilai *accuracy*, *precision*, *recall*, dan F1-*score* menunjukkan bahwa model yang dikembangkan memiliki kinerja optimal dan berpotensi dijadikan sebagai sistem pendukung keputusan dalam melakukan prediksi kualitas udara secara lebih akurat.

Meskipun demikian, penelitian ini memiliki beberapa keterbatasan, terutama pada penggunaan satu teknik balancing data yaitu *Random Undersampling*, serta cakupan data yang masih terbatas pada wilayah dan periode tertentu, sehingga hasilnya belum dapat digeneralisasikan secara luas. Oleh karena itu, penelitian selanjutnya disarankan untuk mengeksplorasi berbagai teknik balancing data dan algoritma lain dengan cakupan data yang lebih besar dan beragam, agar diperoleh hasil yang lebih komprehensif, representatif, dan aplikatif di berbagai kondisi.

4 REFERENSI

[1] F. Widiawati, R. Kurniawan, And T. Suprapti, “Klasifikasi Data Tingkat Kualitas Udara Di Tangerang Selatan Menggunakan Algoritma Naive Bayes,” 2023. Doi: Https://Doi.Org/10.36040/Jati.V7i6.8261.

[2] A. F. B. Sajiwo, B. Rahmat, And A. Junaidi, "Klasifikasi Indeks Standar Pencemaran Udaran (Ispu) Menggunakan Algoritma Xgboost Dengan Teknik Imbalanced Data (Smote)," *Jurnal Informatika Dan Teknik Elektro Terapan*, Vol. 12, No. 3, Aug. 2024, Doi: 10.23960/Jitet.V12i3.4699.

[3] N. Dimas Syandika And W. Yustanti, "Deteksi Anomali Terhadap Pembatalan Transaksi Pada Platform Tiktok Shop Dengan Algoritma Categorical Boosting (Catboost)," *Journal Of Informatics And Computer Science*, Vol. 05, 2023.

[4] O. Pahlevi, D. Ayu, N. Wulandari, L. K. Rahayu, H. Leidiyana, And Y. Handrianto, "Bulletin Of Computer Science Research Model Klasifikasi Risiko Stunting Pada Balita Menggunakan Algoritma Catboost Classifier," *Media Online)*, Vol. 6, No. 4, Pp. 414–421, 2024, Doi: 10.47065/Bulletincsr.V4i6.373.

[5] T. Z. Jasman, M. A. Fadhlullah, A. L. Pratama, And R. Rismayani, "Analisis Algoritma Gradient Boosting, Adaboost Dan Catboost Dalam Klasifikasi Kualitas Air," *Jurnal Teknik Informatika Dan Sistem Informasi*, Vol. 8, No. 2, Aug. 2022, Doi: 10.28932/Jutisi.V8i2.4906.

[6] T. Fulazzaky, A. Saefuddin, And A. M. Soleh, "Evaluating Ensemble Learning Techniques For Class Imbalance In Machine Learning: A Comparative Analysis Of Balanced *Random* Forest, Smote-Rf, Smoteboost, And Rusboost," *Scientific Journal Of Informatics*, Vol. 11, No. 4, Pp. 969–980, Dec. 2024, Doi: 10.15294/Sji.V11i4.15937.

[7] Y. Nurohmah, R. Mayasari, And B. Nurina Sari, "Optimalisasi Performa K-Means Clustering Dengan Pca Dalam Analisis Tingkat Kemiskinan Di Jawa Barat," 2023.

[8] Haris Kurniawan, Sarjon Defit, And Sumijan, "Data Mining Menggunakan Metode K-Means Clustering Untuk Menentukan Besaran Uang Kuliah Tunggal," *Journal Of Applied Computer Science And Technology*, Vol. 1, No. 2, Pp. 80–89, Dec. 2020, Doi: 10.52158/Jacost.V1i2.102.

[9] C. Seiffert, T. M. Khoshgoftaar, J. Van Hulse, And A. Napolitano, "Rusboost: A Hybrid Approach To Alleviating Class Imbalance," *Ieee Transactions On Systems, Man, And Cybernetics Part A:Systems And Humans*, Vol. 40, No. 1, Pp. 185–197, Jan. 2010, Doi: 10.1109/Tsmca.2009.2029559.

[10] U. Hasanah, A. M. Soleh, And K. Sadik, "Effect Of *Random* Under Sampling, Oversampling, And Smote On The Performance Of Cardiovascular Disease Prediction Models," *Jurnal Matematika, Statistika Dan Komputasi*, Vol. 21, No. 1, Pp. 88–102, Sep. 2024, Doi: 10.20956/J.V21i1.35552.

[11] T. Elizabeth, "Prediksi Jenis Kanker Payudara Menggunakan Metode Support Vector Machine Berbasis *Recursive Feature Elimination*," *Julyxxxx*, Vol. X, No.X, Pp. 1–5.

[12] F. Madani1 And A. H. Lubis2, "Jite (Journal Of Informatics And Telecommunication Engineering) Catboost Algorithm Implementation For Classifying Women's Fashion Products," *Jite*, Vol. 9, No. 1, 2025, Doi: 10.31289/Jite.V9i1.15604.

[13] M. Saber *Et Al.*, "Examining Lightgbm And Catboost Models For Wadi Flash Flood Susceptibility Prediction," *Geocarto Int*, Vol. 37, No. 25, Pp. 7462–7487, 2022, Doi: 10.1080/10106049.2021.1974959.

[14] R. G. Gunawan, Erik Suanda Handika, And Edi Ismanto, "Pendekatan Machine Learning Dengan Menggunakan Algoritma Xgboost (Extreme Gradient Boosting) Untuk Peningkatan Kinerja Klasifikasi Serangan Syn," *Jurnal Coscitech (Computer Science And Information Technology)*, Vol. 3, No. 3, Pp. 453–463, Dec. 2022, Doi: 10.37859/Coscitech.V3i3.4356.

[15] M. Norhalimi, T. Azhima, And Y. Siswa, "Optimasi Seleksi Fitur Information Gain Pada Algoritma Naïve Bayes Dan K-Nearest Neighbor," 2022.

[16] R. Mohammed, J. Rawashdeh, And M. Abdullah, "Machine Learning With Oversampling And Undersampling Techniques: Overview Study And Experimental Results," In *2020 11th International Conference On Information And Communication Systems, Icics 2020*, Institute Of Electrical And Electronics Engineers Inc., Apr. 2020, Pp. 243–248. Doi: 10.1109/Icics49469.2020.239556.

[17] A. Riski Indra Pratama *Et Al.*, "Optimasi Klasifikasi Curah Hujan Menggunakan Support Vector Machine (Svm) Dan Recursive Feature Elimination (Rfe)."

[18] B. F. Darst, K. C. Malecki, And C. D. Engelman, "Using Recursive Feature Elimination In Random Forest To Account For Correlated Variables In High Dimensional Data," *Bmc Genet*, Vol. 19, Sep. 2018, Doi: 10.1186/S12863-018-0633-8.