Stacking ensemble Optimasi Genetic Algorithm Prediksi Indeks Standar Pencemar Udara Kota Jakarta

Fahmi Hammam Taqiyuddin[1*], Aviolla Terza Damaliana [2], Andri Fauzan Adziima[3]

[1,2]Sains Data,Fakultas Ilmu Komputer Universitas Pembangunan Nasional "Veteran" Jawa Timur
Email: [1]22083010026@student.upnjatim.ac.id, [2]aviolla.terza.sada@upnjatim.ac.id,
[3]andri.fauzan.fasilkom@upnjatim.ac.id
*Penulis Korespondensi

Abstract*— Air pollution conditions in large cities often change from time to time and can influence environmental quality as well as public health. In Jakarta, air quality information is commonly reported using the Air Pollution Standard Index (ISPU), yet tools for estimating future air quality levels are still limited. This study therefore proposes a predictive modeling approach to estimate daily ISPU values using multivariate time series data collected from air quality monitoring stations available through the Satu Data Jakarta portal. The proposed model applies a stacking ensemble architecture that combines RFand XGB as base learners with Ridge Regression acting as the meta-learner. Hyperparameter tuning is performed using a Genetic Algorithm to obtain a parameter configuration that improves the learning capability of the model. The evaluation process uses a walk-forward recursive forecasting scheme with TimeSeriesSplit, and model performance is assessed using RMSE, MAE, MAPE, and R^2 metrics. Experimental results indicate that the stacking ensemble optimized with a Genetic Algorithm produces the best predictive performance with an RMSE of 1.9802 and R^2 of 0.9902, demonstrating that the proposed approach can improve prediction accuracy for ISPU time series data.

Intisari— Kondisi kualitas udara di kota besar sering mengalami perubahan dari waktu ke waktu dan dapat berdampak pada lingkungan serta kesehatan masyarakat. Di Jakarta, informasi kualitas udara umumnya disajikan dalam bentuk Indeks Standar Pencemar Udara (ISPU), namun ketersediaan metode untuk memperkirakan kondisi kualitas udara di masa mendatang masih terbatas. Oleh karena itu penelitian ini mengusulkan pendekatan pemodelan prediksi untuk memperkirakan nilai ISPU harian menggunakan data deret waktu multivariat yang diperoleh dari stasiun pemantauan kualitas udara melalui portal Satu Data Jakarta. Model yang digunakan menerapkan arsitektur *stacking ensemble* yang menggabungkan RF dan XGB sebagai base learner serta Ridge Regression sebagai meta-learner. Proses penyesuaian hyperparameter dilakukan menggunakan Genetic Algorithm untuk memperoleh konfigurasi parameter yang mampu meningkatkan kemampuan pembelajaran model. Evaluasi dilakukan menggunakan skema walk-forward recursive forecasting berbasis TimeSeriesSplit dengan metrik penilaian RMSE, MAE, MAPE, dan R^2. Hasil eksperimen menunjukkan bahwa model *stacking ensemble* yang dioptimasi dengan Genetic Algorithm menghasilkan performa terbaik dengan RMSE sebesar 1.9802 dan R^2 sebesar 0.9902 sehingga pendekatan ini mampu meningkatkan akurasi prediksi pada data deret waktu ISPU.

***Kata Kunci*— Prediksi ISPU, Stacking Ensemble, Genetic Algorithm, Deret Waktu, Kualitas Udara.**

I. PENDAHULUAN

Kualitas udara menjadi salah satu isu lingkungan yang semakin mendapat perhatian di berbagai kota besar di dunia, khususnya pada kawasan perkotaan yang memiliki intensitas aktivitas manusia yang tinggi. Peningkatan jumlah kendaraan bermotor, ekspansi kawasan industri, serta pertumbuhan aktivitas ekonomi merupakan beberapa faktor yang berkontribusi terhadap meningkatnya emisi polutan di atmosfer. Kondisi tersebut berpotensi menurunkan kualitas udara ambien dan memberikan dampak terhadap lingkungan perkotaan maupun kesehatan masyarakat. Sejumlah penelitian menunjukkan bahwa perkembangan transportasi dan urbanisasi memiliki keterkaitan dengan peningkatan konsentrasi polutan udara di berbagai kota di Indonesia [1]. Sejumlah penelitian menunjukkan bahwa perkembangan transportasi dan urbanisasi memiliki keterkaitan dengan peningkatan konsentrasi polutan udara di berbagai kota di Indonesia [2] Sebagai salah satu wilayah metropolitan dengan tingkat mobilitas yang tinggi, Jakarta juga menghadapi permasalahan kualitas udara yang cukup serius, di mana sektor transportasi diketahui menjadi salah satu sumber utama emisi pencemar udara di wilayah tersebut [3].

Untuk menggambarkan kondisi kualitas udara secara terstandarisasi, pemerintah Indonesia menggunakan indikator yang dikenal sebagai Indeks Standar Pencemar Udara (ISPU). Indeks ini digunakan untuk menunjukkan tingkat kualitas udara ambien pada suatu lokasi berdasarkan konsentrasi beberapa parameter pencemar udara yang berpengaruh terhadap kesehatan manusia dan lingkungan. Dalam perhitungan ISPU, terdapat beberapa parameter utama yang digunakan, antara lain partikulat berukuran kurang dari 10 mikrometer (PM10), partikulat berukuran kurang dari 2,5 mikrometer (PM2.5), karbon monoksida (CO), nitrogen dioksida (NO_2), sulfur dioksida (SO_2), serta ozon (O_3). Parameter tersebut diperoleh melalui proses pemantauan kualitas udara ambien yang dilakukan secara kontinu menggunakan stasiun pemantauan kualitas udara. Pada penelitian ini, data yang digunakan meliputi parameter PM10, PM2.5, CO, NO_2, SO_2, dan O_3 [4].

Peningkatan konsentrasi polutan udara di wilayah perkotaan dapat menimbulkan berbagai dampak negatif terhadap kesehatan manusia maupun kondisi lingkungan. Partikel polutan seperti PM2.5 dan PM10 memiliki ukuran yang sangat kecil sehingga dapat masuk ke dalam sistem pernapasan dan memicu berbagai gangguan kesehatan. Paparan polusi udara dalam jangka waktu yang panjang diketahui berkaitan dengan meningkatnya risiko penyakit pernapasan serta gangguan kardiovaskular pada Masyarakat perkotaan [5]. Selain itu, kualitas udara yang buruk juga dapat meningkatkan jumlah

individu yang rentan terhadap berbagai penyakit akibat paparan polutan secara terus menerus. Sejumlah penelitian juga menunjukkan bahwa paparan jangka panjang terhadap partikel polutan di udara memiliki hubungan yang signifikan dengan meningkatnya risiko gangguan kesehatan pada populasi yang tinggal di wilayah dengan tingkat polusi tinggi [6].

Di Jakarta, informasi mengenai kondisi kualitas udara disajikan melalui nilai Indeks Standar Pencemar Udara (ISPU) yang dihitung berdasarkan data hasil pemantauan dari stasiun pemantauan kualitas udara ambien. Sistem ini memungkinkan masyarakat memperoleh informasi kondisi kualitas udara pada waktu tertentu melalui kategori seperti baik, sedang, tidak sehat, sangat tidak sehat, hingga berbahaya. Data kualitas udara yang digunakan dalam penelitian ini diperoleh dari portal Satu Data Jakarta yang mengintegrasikan data pemantauan dari lima stasiun kualitas udara di wilayah DKI Jakarta sehingga dapat memberikan gambaran kondisi kualitas udara secara lebih menyeluruh di kawasan perkotaan. Meskipun sistem pemantauan tersebut mampu menyediakan informasi kondisi kualitas udara secara *real-time*, informasi yang tersedia umumnya masih terbatas pada kondisi udara yang sedang terjadi sehingga belum dapat digunakan untuk memperkirakan perubahan kualitas udara di masa mendatang [7]. Oleh karena itu, pengembangan metode prediksi kualitas udara berbasis data menjadi penting untuk memahami pola perubahan konsentrasi polutan serta mendukung pengelolaan kualitas udara yang lebih proaktif di wilayah perkotaan. Berbagai penelitian menunjukkan bahwa pendekatan pembelajaran mesin mampu memodelkan hubungan kompleks antar variabel lingkungan sehingga dapat meningkatkan kemampuan prediksi kualitas udara [8]. Selain itu, penerapan kecerdasan buatan dalam berbagai bidang menunjukkan bahwa metode machine learning mampu melakukan proses analisis dan klasifikasi data secara efektif dengan tingkat akurasi yang baik[9].

Untuk mengatasi keterbatasan sistem pemantauan yang hanya menampilkan kondisi udara secara real-time, berbagai penelitian mulai mengembangkan metode prediksi kualitas udara berbasis pembelajaran mesin. Pendekatan ini memanfaatkan data historis kualitas udara untuk mempelajari pola hubungan antar parameter polutan dan variabel lingkungan sehingga dapat digunakan untuk memperkirakan kondisi kualitas udara di masa mendatang. Beberapa algoritma pembelajaran mesin seperti RF dan XGB telah banyak digunakan dalam penelitian prediksi kualitas udara karena mampu menangani hubungan non-linear antar variabel serta memiliki performa yang baik dalam pemodelan data lingkungan [10]. Selain penggunaan model tunggal, pendekatan ensemble learning juga mulai banyak diterapkan untuk meningkatkan performa prediksi dengan menggabungkan beberapa model dalam satu kerangka kerja [11]. Sejumlah penelitian juga menunjukkan bahwa penerapan model berbasis kecerdasan buatan mampu menghasilkan tingkat akurasi yang tinggi dalam proses analisis data kompleks, sehingga berpotensi meningkatkan kualitas hasil prediksi dibandingkan pendekatan konvensional [12]Salah satu metode ensemble yang banyak digunakan adalah *stacking ensemble*, yaitu pendekatan yang mengombinasikan beberapa model dasar dan memanfaatkan model meta untuk menghasilkan prediksi yang lebih akurat dibandingkan penggunaan model tunggal [13].

Selain pemilihan algoritma yang tepat, performa model prediksi juga sangat dipengaruhi oleh proses penentuan parameter yang digunakan dalam pelatihan model. Parameter yang tidak optimal dapat menyebabkan model menghasilkan prediksi yang kurang akurat meskipun algoritma yang digunakan memiliki kemampuan pemodelan yang baik. Oleh karena itu, proses optimasi parameter menjadi salah satu tahap penting dalam pengembangan model pembelajaran mesin. Salah satu metode optimasi yang banyak digunakan adalah *Genetic Algorithm* (GA) yang bekerja dengan meniru mekanisme evolusi biologis melalui proses seleksi, *crossover*, dan mutasi untuk menemukan kombinasi parameter terbaik [14]. Pendekatan ini memungkinkan proses pencarian parameter dilakukan secara lebih efektif pada ruang pencarian yang luas sehingga berpotensi meningkatkan performa model dibandingkan penggunaan parameter awal atau *baseline* [15]. Beberapa penelitian juga menunjukkan bahwa penerapan *Genetic Algorithm* dalam dalam proses optimasi model prediksi kualitas udara mampu meningkatkan akurasi model dalam mempelajari pola kompleks pada data kualitas udara [16].

Berdasarkan permasalahan tersebut, penelitian ini bertujuan untuk mengembangkan model prediksi kualitas udara yang mampu memperkirakan kondisi ISPU di wilayah Jakarta menggunakan pendekatan pembelajaran mesin. Model yang diusulkan menggunakan metode *stacking ensemble* dengan menggabungkan algoritma *RF dan XGB* sebagai base learner serta *Ridge Regression* sebagai meta learner untuk meningkatkan kemampuan model dalam mempelajari pola data kualitas udara. Data yang digunakan berasal dari lima stasiun pemantauan kualitas udara di wilayah DKI Jakarta yang tersedia melalui portal Satu Data Jakarta. Penelitian ini juga menerapkan *Genetic Algorithm* sebagai metode optimasi untuk mencari kombinasi parameter model yang lebih optimal sehingga diharapkan dapat meningkatkan performa model prediksi. Melalui pendekatan tersebut penelitian ini diharapkan dapat menghasilkan model prediksi kualitas udara yang lebih akurat serta memberikan informasi yang dapat mendukung pengelolaan kualitas udara secara lebih proaktif di wilayah perkotaan [16].

II. TINJAUAN PUSTAKA

Tinjauan pustaka pada penelitian ini memuat konsep-konsep utama yang menjadi dasar dalam pengembangan model prediksi kualitas udara berbasis deret waktu. Berikut adalah uraian teoritis mengenai Indeks Standar Pencemar Udara (ISPU) sebagai indikator utama dalam penelitian ini.

A. Multivariate Time Series

Multivariate time series merupakan data deret waktu yang terdiri dari beberapa variabel yang diamati secara berurutan pada periode waktu tertentu. Data jenis ini banyak ditemukan pada berbagai bidang seperti energi, lalu lintas, ekonomi, cuaca, dan kesehatan. Dalam analisis deret waktu, nilai suatu variabel pada waktu tertentu biasanya berkaitan dengan nilai pada waktu sebelumnya. Hubungan antar waktu tersebut membentuk pola temporal yang dapat dipelajari oleh model prediksi [17].

B. Autocorrelation Function (ACF) dan Partial Autocorrelation Function (PACF)

ACF merupakan metode yang digunakan untuk mengukur hubungan antara nilai suatu data deret waktu dengan nilai pada periode sebelumnya. Analisis ini dilakukan dengan menghitung korelasi antara observasi pada waktu tertentu dengan observasi pada beberapa lag waktu. Nilai ACF membantu menggambarkan seberapa kuat hubungan antar waktu dalam suatu data deret waktu. Melalui pola pada grafik ACF, peneliti dapat mengidentifikasi karakteristik hubungan temporal dalam data.

PACF digunakan untuk mengukur hubungan parsial antara suatu observasi dengan lag tertentu setelah pengaruh lag sebelumnya dihilangkan. Analisis ini membantu melihat kontribusi langsung dari suatu lag terhadap nilai observasi pada waktu sekarang. Dengan menggunakan PACF, pengaruh dari lag lain yang tidak relevan dapat dikurangi sehingga hubungan utama dalam data menjadi lebih jelas. Grafik PACF sering digunakan untuk membantu menentukan orde model dalam analisis deret waktu. Oleh karena itu, analisis PACF biasanya digunakan bersama dengan ACF untuk mengidentifikasi struktur model yang paling sesuai [18].

C. Time Series Split (TSS)

Time Series Split merupakan teknik validasi model yang digunakan untuk mengevaluasi kinerja model pada data deret waktu. Metode ini bekerja dengan membagi data menjadi dua bagian yaitu data pelatihan untuk membangun model dan data pengujian untuk menilai performa model. Berbeda dengan validasi acak, pembagian data pada deret waktu harus mempertahankan urutan kronologis agar hubungan temporal antar data tetap terjaga. Pendekatan ini penting karena setiap observasi dalam data deret waktu biasanya dipengaruhi oleh observasi sebelumnya. Oleh karena itu, teknik data *splitting* atau *cross-validation* sering digunakan untuk menilai kinerja model prediksi secara lebih objektif pada data deret waktu [19].

D. Stacking ensemble

Stacking ensemble merupakan teknik pembelajaran mesin yang menggabungkan beberapa model prediksi untuk menghasilkan kinerja yang lebih baik dibandingkan penggunaan satu model tunggal. Pendekatan ini bekerja dengan cara melatih beberapa model dasar (*base learner*) secara terpisah, kemudian hasil prediksi dari masing-masing model tersebut digunakan sebagai masukan bagi model lain yang berperan sebagai penggabung atau meta-model. Meta-model tersebut akan mempelajari pola hubungan antara prediksi model dasar sehingga dapat menghasilkan prediksi akhir yang lebih akurat dan stabil. Pendekatan stacking memungkinkan setiap model memanfaatkan keunggulan masing-masing dalam menangkap karakteristik data yang berbeda, seperti pola linear maupun *nonlinear*. Dengan mengintegrasikan hasil prediksi dari beberapa model melalui *meta model*, metode *stacking* dapat meningkatkan akurasi dan keandalan proses prediksi pada permasalahan deret waktu maupun aplikasi prediktif lainnya[20].

E. Genetic Algorithm (GA)

Genetic Algorithm (GA) merupakan metode optimasi berbasis evolusi yang meniru proses seleksi alam untuk menemukan solusi terbaik dari suatu permasalahan pencarian. Algoritma ini bekerja dengan membentuk populasi awal yang terdiri dari beberapa kandidat solusi yang direpresentasikan sebagai kromosom, kemudian mengevaluasi kualitas setiap solusi menggunakan fungsi fitness. Proses evolusi selanjutnya dilakukan melalui tiga operator utama yaitu seleksi, *crossover*, dan mutasi untuk menghasilkan generasi solusi baru. Pada tahap seleksi, kromosom dengan nilai fitness yang lebih baik memiliki peluang lebih besar untuk dipilih, sedangkan proses *crossover* dan mutasi digunakan untuk menghasilkan variasi solusi baru dalam populasi. Melalui proses iterasi yang berulang hingga mencapai jumlah generasi tertentu atau kondisi penghentian, *genetic algorithm* mampu mengeksplorasi ruang pencarian secara efisien sehingga sering digunakan untuk optimasi parameter pada model machine learning[21].

F. Matriks Evaluasi

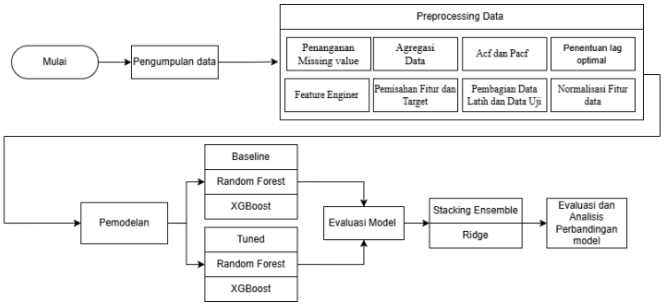
Evaluasi model peramalan dilakukan menggunakan beberapa metrik kesalahan untuk menilai kinerja model dalam memprediksi data deret waktu. Dalam penelitian peramalan, teknik validasi yang sering digunakan adalah *walk-forward validation* Pendekatan ini mempertahankan urutan temporal sehingga lebih sesuai untuk evaluasi model pada data deret waktu dibandingkan pembagian data secara acak. Melalui pendekatan walk-forward, performa model dapat dianalisis secara lebih realistis karena proses evaluasi meniru kondisi prediksi pada situasi nyata. Oleh karena itu, penggunaan metrik evaluasi seperti MAE, RMSE, MAPE, dan koefisien determinasi (R^2) bersama dengan *walk-forward validation* [22].

III. METODE PENELITIAN

Penelitian ini menggunakan pendekatan studi kuantitatif eksperimental yang bertujuan untuk mengevaluasi kinerja beberapa model machine learning dalam memprediksi nilai Indeks Standar Pencemar Udara (ISPU). Studi kasus difokuskan pada wilayah Kota Jakarta dengan memanfaatkan data harian kualitas udara pada periode 1 Januari 2023 hingga 30 November 2025. Dataset yang digunakan bersifat terbuka dan diperoleh dari portal resmi pemerintah melalui platform Satu Data Jakarta yang dapat diakses melalui situs https://satudata.jakarta.go.id/home Pendekatan yang digunakan dalam penelitian ini adalah peramalan deret waktu, dengan memanfaatkan algoritma *RF dan XGB* sebagai model dasar dalam proses pemodelan.

Penelitian ini mengembangkan pendekatan *stacking ensemble* dengan memanfaatkan Ridge Regression sebagai meta-learner. Proses penyesuaian parameter model dilakukan melalui teknik optimasi hyperparameter menggunakan *Genetic Algorithm* untuk memperoleh kombinasi parameter yang lebih optimal selama proses pelatihan model. Evaluasi performa model dilakukan dengan menggunakan beberapa metrik pengukuran, yaitu Root Mean Square Error (RMSE), Mean Absolute Error (MAE), Mean Absolute Percentage Error (MAPE), serta koefisien determinasi (R^2) guna menilai tingkat akurasi prediksi yang dihasilkan oleh masing-masing model.

Seluruh tahapan penelitian dirangkum dalam diagram alir penelitian yang disajikan pada Gambar 1.



Gambar 1 Diagram Alir Penelitian

A. Research Framework

Kerangka penelitian ini dirancang untuk menjelaskan tahapan utama yang dilakukan dalam proses pengembangan model prediksi ISPU. Penelitian diawali dengan tahap pengumpulan data yang bersumber dari portal Satu Data Jakarta. Data yang telah diperoleh selanjutnya melalui proses prapemrosesan untuk memastikan kualitas dan konsistensi data sebelum digunakan dalam tahap pemodelan. Tahapan ini meliputi penanganan nilai yang hilang, analisis pola pada data deret waktu, serta pembentukan variabel lag yang relevan. Setelah seluruh proses prapemrosesan selesai dilakukan, dataset kemudian dipersiapkan untuk digunakan pada tahap pembangunan model prediksi.

Pada tahap pemodelan, algoritma *RF* dan XGB digunakan sebagai model dasar untuk menghasilkan prediksi awal terhadap nilai ISPU. Kedua algoritma tersebut berfungsi sebagai base learner dalam arsitektur *stacking ensemble*. Prediksi yang dihasilkan oleh masing-masing model dasar kemudian digunakan sebagai input bagi model pada tingkat berikutnya. Dalam penelitian ini, *Ridge Regression* digunakan sebagai *meta learner* yang bertugas menggabungkan hasil prediksi dari kedua model dasar tersebut. Setelah proses pembentukan model *stacking* selesai, dilakukan optimasi *hyperparameter* menggunakan *Genetic Algorithm* untuk memperoleh konfigurasi parameter yang lebih optimal.

A. Data Collection

Dataset yang digunakan dalam penelitian ini berupa data harian Indeks Standar Pencemar Udara (ISPU). Data tersebut terdiri dari beberapa parameter polutan udara yang umum digunakan dalam pemantauan kualitas udara. Parameter yang digunakan meliputi PM10, PM2.5, SO_2, CO, O_3, dan NO_2. Struktur data yang digunakan dalam penelitian ini ditunjukkan pada Tabel 1.

Tabel 1 Data Penelitian

tanggal	pm10	pm25	so2	co	o3	no2	max
2023-01-01	44	55	47	10	24	9	55
2023-01-02	32	43	52	9	24	8	52
2024-01-01	64	89	52	9	13	30	89
2025-11-30	52	79	40	15	22	28	79
2025-11-31	59	88	35	15	16	33	88

Tabel tersebut menunjukkan contoh struktur dataset yang digunakan dalam penelitian ini. Setiap baris merepresentasikan satu observasi harian dari data kualitas udara. Nilai pada setiap kolom menunjukkan konsentrasi polutan yang diukur pada hari pengamatan. Kolom *Max* menunjukkan nilai polutan tertinggi yang digunakan untuk menentukan tingkat kualitas udara pada hari tersebut. Dataset lengkap kemudian digunakan sebagai input pada tahap prapemrosesan dan pemodelan

B. Data Preprocessing

Tahap prapemrosesan data dilakukan untuk memastikan kualitas dan konsistensi dataset sebelum digunakan dalam proses pemodelan. Pada tahap awal dilakukan pemeriksaan struktur data serta identifikasi nilai yang hilang pada setiap variabel polutan. *Missing value* pada parameter PM10, PM2.5, SO_2, CO, O_3, dan NO_2 ditangani melalui proses imputasi untuk menjaga kelengkapan data. Selanjutnya dilakukan pengujian stasioneritas untuk mengetahui apakah data memiliki pola yang stabil sepanjang waktu. Jika data belum stasioner maka dilakukan proses *differencing* untuk menstabilkan pola deret waktu.

Setelah data mencapai kondisi yang lebih stabil, dilakukan analisis (ACF) dan (PACF) untuk memahami hubungan antar waktu dalam data deret waktu. Hasil analisis tersebut digunakan sebagai dasar dalam menentukan jumlah lag yang digunakan pada model prediksi. Dalam penelitian ini digunakan sebanyak tujuh *lag* untuk merepresentasikan pengaruh nilai pengamatan pada periode sebelumnya. Dataset kemudian dipisahkan menjadi data latih dan data uji dengan rasio 70:30 berdasarkan urutan waktu. Setelah proses pemisahan data dilakukan, fitur pada dataset dinormalisasi untuk menjaga skala variabel agar tetap seimbang selama proses pelatihan model.

C. Random Forest

RF merupakan metode *ensemble* berbasis pohon keputusan yang menghasilkan prediksi melalui agregasi dari sejumlah model pohon yang dibangun secara independen. Metode ini bekerja dengan pendekatan *bagging*, yaitu membangun beberapa model pohon keputusan menggunakan subset data latih yang dipilih secara acak. Selain itu, pada setiap proses pemisahan node hanya sebagian fitur yang dipilih secara acak sehingga meningkatkan variasi antar pohon. Pendekatan ini membantu mengurangi risiko *overfitting* serta meningkatkan kemampuan generalisasi model pada data baru [23].

Pada permasalahan regresi, hasil prediksi *RF*diperoleh dengan menggabungkan keluaran dari seluruh pohon keputusan yang terbentuk. Prediksi akhir dihitung sebagai rata-rata dari seluruh prediksi pohon dalam *model ensemble*. Secara matematis, prediksi *RF* dapat dinyatakan sebagai berikut:

$$\hat{y} = \frac{1}{B}\sum_{b=1}^{B} T_b(x) \quad (1)$$

di mana $\hat{y}$ merupakan nilai prediksi akhir, B enyatakan jumlah pohon keputusan dalam model, dan $T_b(x)$ merupakan prediksi dari pohon ke-b terhadap input x.

D. Extreme Gradient Boosting (XGB)

XGB merupakan algoritma machine learning berbasis teknik *boosting* yang membangun model secara bertahap menggunakan sejumlah pohon keputusan. Berbeda dengan metode *bagging* seperti RF, XGB membangun model secara sekuensial dengan memperbaiki kesalahan prediksi pada

iterasi sebelumnya. Setiap pohon baru dibangun untuk meminimalkan residual yang dihasilkan oleh model sebelumnya sehingga performa prediksi meningkat secara bertahap. Pendekatan ini memungkinkan XGB menangkap hubungan nonlinier yang kompleks dalam data. Karena efisiensi dan akurasinya, XGB banyak digunakan dalam berbagai permasalahan prediksi berbasis machine learning[24].

Secara umum, XGB meminimalkan fungsi objektif yang terdiri dari fungsi kerugian dan komponen regularisasi untuk mengontrol kompleksitas model. Bentuk umum fungsi objektif XGB dapat dinyatakan sebagai berikut:

$$\mathcal{L}^{(t)} = \sum_{i=1}^{N} (y_i, \hat{y}_i^{(t-1)} + f_t(x_i) + \Omega\, f_t) \quad (2)$$

di mana $l(\cdot)$ adalah fungsi kerugian yang mengukur selisih antara nilai aktual $y_i$dan prediksi $\hat{y}_i$, sedangkan $f_t(x_i)$ menyatakan model pohon keputusan pada iterasi ke-t. Komponen regulasi $\Omega(f_t)$ digunakan untuk mengontrol kompleksitas model sehingga dapat mengurangi risiko *overfitting*.

E. Stacking ensemble

Stacking ensemble merupakan teknik *ensemble learning* yang menggabungkan beberapa model dasar untuk menghasilkan prediksi yang lebih akurat. Metode ini bekerja dengan melatih beberapa *base learner* pada tingkat pertama, kemudian menggunakan prediksi dari model tersebut sebagai input bagi model tingkat kedua atau *meta learner*. Pendekatan ini memungkinkan model *meta* mempelajari pola kesalahan dari masing-masing model dasar dan mengkombinasikannya secara optimal. Dalam penelitian ini digunakan *RF dan XGB* sebagai *base learner* pada tahap pertama.

Prediksi yang dihasilkan oleh masing-masing base learner kemudian digunakan sebagai fitur baru untuk membangun model meta. Model meta bertugas menggabungkan informasi dari berbagai model dasar sehingga menghasilkan prediksi yang lebih stabil. Secara umum model stacking dapat dinyatakan sebagai berikut:

$$\hat{y} = g(h_1(x), h_2(x), \dots, h_M(x)) \quad (3)$$

Di mana $h_1(x), h_2(x), \dots, h_M(x)$, merupakan prediksi dari model dasar dan $g(\cdot)$ merupakan fungsi *meta-learner*.

Dalam penelitian ini digunakan Ridge Regression sebagai meta-learner untuk menggabungkan keluaran dari model dasar. Ridge Regression merupakan metode regresi linear yang menerapkan regularisasi L2 untuk mengurangi masalah multikolinearitas dan menjaga stabilitas model. Secara matematis fungsi objektif Ridge Regression dapat dinyatakan sebagai berikut:

$$\hat{\beta} = argmin \left(\sum_{i=1}^{N} (y_i, -X_i\beta)^2 + \lambda \sum_{j=1}^{p} \beta_j^2 \right) \quad (4)$$

Parameter λ mengontrol besar penalti terhadap koefisien regresi sehingga model dapat mengurangi kompleksitas dan meningkatkan kemampuan generalisasi terhadap data baru.

F. Hyperparameter Optimization Genetic Algorithm

Hyperparameter optimization merupakan tahap penting dalam pengembangan model pembelajaran mesin untuk memperoleh konfigurasi parameter yang menghasilkan performa prediksi optimal. Pada penelitian ini, proses optimasi dilakukan menggunakan *Genetic Algorithm* yang diterapkan pada model yang digunakan dalam arsitektur *stacking ensemble*. Pendekatan ini memungkinkan eksplorasi berbagai kombinasi parameter secara sistematis dalam ruang pencarian yang telah ditentukan. Setiap kombinasi parameter dievaluasi menggunakan nilai *fitness* yang diperoleh dari performa model selama proses pelatihan.

Proses optimasi dilakukan dengan merepresentasikan setiap kombinasi *hyperparameter* sebagai kandidat solusi yang kemudian dievaluasi pada setiap iterasi proses evolusi. Kandidat solusi dengan performa yang lebih baik memiliki peluang lebih besar untuk dipertahankan pada generasi berikutnya sehingga proses pencarian dapat mengarah pada konfigurasi parameter yang lebih optimal. Melalui mekanisme ini, *Genetic Algorithm* mampu menemukan kombinasi hyperparameter yang memberikan kinerja model yang lebih stabil dan akurat.

Proses optimasi pertama diterapkan pada model *RF*dengan menentukan ruang pencarian *hyperparameter* yang relevan terhadap proses pembentukan pohon keputusan. Rentang nilai parameter yang digunakan pada tahap optimasi RFditunjukkan pada Tabel 2.

Tabel 2 Parameter *Random Forest*

Hyperparameter	*Type*	*Range*
n_estimators	*Int*	50 – 200
max_depth	*Int*	3 – 12
min_samples_split	*Int*	2 – 10
min_samples_leaf	*Int*	1 – 5
max_features	*Continuous*	0.4 – 1.0

Selanjutnya, proses optimasi juga diterapkan pada model XGB untuk menentukan konfigurasi parameter yang mampu meningkatkan kemampuan model dalam mempelajari pola data. Ruang pencarian *hyperparameter* yang digunakan pada optimasi model XGB ditunjukkan pada Tabel 3.

Tabel 3 Parameter *XGB*

Hyperparameter	*Type*	*Range*
n_estimators	*Int*	50 – 300
max_depth	*Int*	2 – 8
learning_rate	*Continuous*	0.01 – 0.10
subsample	*Continuous*	0.5 – 1.0
colsample_bytree	*Continuous*	0.5 – 1.0

Dalam penelitian ini, proses optimasi menggunakan *Genetic Algorithm* dilakukan dengan ukuran populasi sebanyak 7 individu dan jumlah generasi sebanyak 7 iterasi.

G. Matriks Evaluasi

Evaluasi kinerja model dilakukan untuk mengukur tingkat akurasi serta kemampuan model dalam melakukan prediksi terhadap data yang belum pernah diamati sebelumnya. Pada penelitian ini digunakan empat metrik evaluasi yaitu *Root* RMSE, MAE, MAPE, dan R^2.

Pada penelitian ini proses evaluasi dilakukan menggunakan pendekatan *walk forward validation* untuk mempertahankan struktur temporal pada data deret waktu. Metode ini bekerja dengan melatih model menggunakan data historis hingga periode tertentu, kemudian melakukan prediksi pada periode waktu berikutnya secara bertahap. Setelah prediksi dilakukan, data observasi terbaru dimasukkan kembali ke dalam dataset pelatihan sebelum proses prediksi selanjutnya dilakukan. Pendekatan ini memungkinkan proses evaluasi dilakukan secara lebih realistis karena mengikuti urutan waktu sebagaimana kondisi pada proses prediksi sebenarnya.

RMSE digunakan untuk mengukur akar dari rata-rata kuadrat selisih antara nilai aktual dan nilai prediksi. Metrik ini memberikan penalti lebih besar terhadap kesalahan prediksi yang memiliki nilai ekstrem karena adanya proses kuadrat dalam perhitungannya. Secara matematis RMSE dapat dirumuskan sebagai berikut

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y})^2} \quad (5)$$

MAE menghitung rata-rata nilai absolut dari selisih antara nilai aktual dan nilai prediksi. Berbeda dengan RMSE, metrik ini tidak memberikan penalti tambahan terhadap kesalahan besar sehingga dapat menggambarkan rata-rata kesalahan prediksi secara lebih langsung. Persamaan MAE dapat dituliskan sebagai berikut.

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i| \quad (6)$$

MAPE digunakan untuk mengukur besarnya kesalahan prediksi dalam bentuk persentase terhadap nilai aktual sehingga memudahkan interpretasi performa model. Secara matematis MAPE dirumuskan sebagai berikut.

$$MAPE = \frac{1}{n}\sum_{i=1}^{n}\left|\frac{y_i - \hat{y}_i}{y_i}\right| \times 100\% \quad (7)$$

R^2 digunakan untuk mengukur seberapa besar variasi data aktual yang mampu dijelaskan oleh model prediksi. Nilai R^2 berada pada rentang 0 hingga 1, di mana nilai yang semakin mendekati 1 menunjukkan kemampuan prediksi model yang semakin baik. Persamaan R^2 dapat dinyatakan sebagai berikut:

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y}_i)^2} \quad (8)$$

IV. HASIL DAN PEMBAHASAN

A. Kinerja Model Baseline

Pada tahap awal eksperimen dilakukan evaluasi terhadap model baseline untuk mengetahui kemampuan dasar masing-masing algoritma dalam memprediksi nilai Indeks Standar Pencemar Udara (ISPU). Model yang digunakan pada tahap ini meliputi RF, XGB, serta *model stacking* yang menggabungkan kedua algoritma tersebut. Evaluasi dilakukan menggunakan skema *walk forward recursive forecasting* untuk mempertahankan struktur temporal pada data deret waktu. Pendekatan ini memungkinkan model melakukan prediksi secara bertahap menggunakan informasi historis dari periode sebelumnya. Hasil evaluasi performa model *baseline* ditunjukkan pada Tabel 4.

Tabel 4 Hasil evaluasi kinerja model *baseline*

Model	MAE	RMSE	MAPE	R^2
RF Baseline	9.1567	12.1340	12.8217	0.6311
XGB Baseline	6.5170	10.1641	9.4490	0.7412
Stack Baseline	4.8405	7.3414	6.7578	0.8650

Berdasarkan hasil pada Tabel 4, terlihat bahwa model *RF*dengan konfigurasi default menghasilkan performa yang paling rendah dibandingkan model lainnya. Hal ini menunjukkan bahwa tanpa penyesuaian parameter, *RF*belum mampu merepresentasikan pola temporal pada data ISPU secara optimal. Model XGB menghasilkan performa yang lebih baik dibandingkan RFdengan nilai RMSE yang lebih rendah serta nilai R^2 yang lebih tinggi. Sementara itu, model stacking baseline yang menggabungkan *RF dan XGB* menunjukkan peningkatan performa dibandingkan model tunggal. Hasil ini menunjukkan bahwa pendekatan *ensemble* dapat meningkatkan stabilitas prediksi bahkan sebelum dilakukan proses optimasi parameter.

B. Optimasi Hyperparameter dengan Genetic Algorithm

Optimasi hyperparameter dilakukan untuk meningkatkan performa model dengan mencari kombinasi parameter yang paling sesuai terhadap karakteristik data deret waktu. Pada penelitian ini proses optimasi dilakukan menggunakan Genetic Algorithm yang diterapkan pada model RF dan XGB. Metode ini bekerja dengan mengeksplorasi berbagai kombinasi parameter melalui proses evolusi yang melibatkan seleksi, crossover, dan mutasi. Setiap kandidat solusi dievaluasi berdasarkan performa model selama proses pelatihan menggunakan skema *walk-forward recursive forecasting*. Hasil evaluasi model setelah proses optimasi ditunjukkan pada Tabel 5.

Tabel 5 Hasil evaluasi model optimasi *Genetic Algorithm*

Model	MAE	RMSE	MAPE	R^2
RF+ GA + TSS	3.4783	5.2849	6.2117	0.9300
XGB + GA + TSS	0.9544	2.0408	1.7433	0.9896
Stacking + GA + TSS	1.1906	1.9802	2.0698	0.9902

Berdasarkan hasil pada Tabel 5, optimasi *hyperparameter* menggunakan *Genetic Algorithm* memberikan peningkatan performa yang signifikan pada model *Random Forest*. Nilai RMSE pada *RF* menurun secara drastis dibandingkan konfigurasi *baseline*. Hasil ini menunjukkan bahwa *Genetic Algorithm* mampu menemukan kombinasi parameter yang lebih optimal dibandingkan konfigurasi *default*. Secara umum, optimasi *hyperparameter* memberikan kontribusi penting dalam meningkatkan performa model sebelum digunakan dalam arsitektur *ensemble* pada tahap selanjutnya.

C. Perbandingan Kinerja Seluruh

Setelah dilakukan evaluasi terhadap model *baseline* serta model yang telah dioptimasi menggunakan *Genetic Algorithm*, langkah selanjutnya adalah membandingkan seluruh model untuk mengidentifikasi konfigurasi dengan performa terbaik. Perbandingan ini bertujuan untuk menganalisis pengaruh optimasi *hyperparameter* serta penggunaan arsitektur *stacking ensemble* terhadap peningkatan akurasi prediksi. Evaluasi dilakukan menggunakan metrik MAE, RMSE, MAPE, dan koefisien determinasi (R^2) dengan skema *walk forward recursive forecasting* untuk menjaga konsistensi struktur temporal data. Melalui pendekatan ini, performa setiap model dapat dianalisis secara objektif berdasarkan kemampuan prediksi terhadap data deret waktu. Hasil perbandingan seluruh model ditunjukkan pada Tabel berikut.

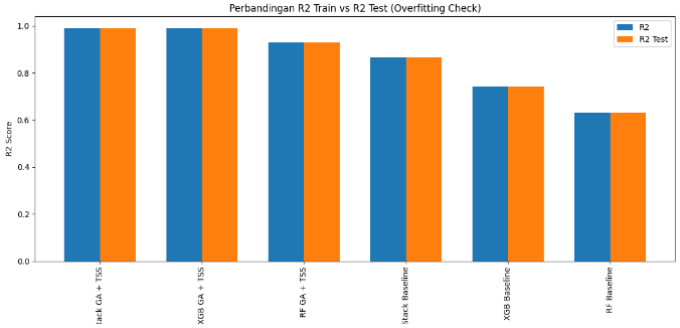
Tabel 6 Perbandingan kinerja seluruh model

Model	MAE	RMSE	MAPE	R^2
RF Baseline	9.1567	12.1340	12.8217	0.6311
XGB Baseline	6.5170	10.1641	9.4490	0.7412
Stack Baseline	4.8405	7.3414	6.7578	0.8650
RF+ GA + TSS	3.4783	5.2849	6.2117	0.9300
XGB + GA + TSS	0.9544	2.0408	1.7433	0.9896
Stacking + GA + TSS	1.1906	1.9802	2.0698	0.9902

Berdasarkan hasil pada Tabel 6, terlihat bahwa proses optimasi *hyperparameter* menggunakan *Genetic Algorithm* memberikan peningkatan performa yang signifikan pada seluruh model. *RF*mengalami peningkatan yang cukup besar setelah optimasi, di mana nilai RMSE menurun dari 12.134 pada konfigurasi *baseline* menjadi 5.2849 setelah proses tuning. Model XGB menunjukkan performa yang lebih baik dibanding *RF*dengan RMSE sebesar 2.0408 dan nilai R^2 mencapai 0.9896. Selain itu, model *stacking* yang menggabungkan *RF dan XGB* menghasilkan performa yang paling stabil dengan RMSE sebesar 1.9802 dan R^2 sebesar 0.9902.

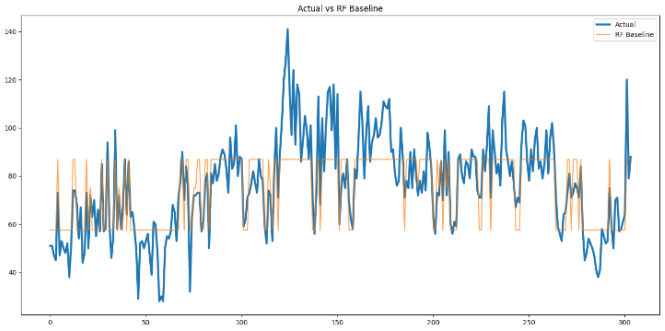
D. Perbandingan Kinerja Seluruh

Analisis visual dilakukan untuk mengevaluasi kemampuan model dalam mengikuti pola perubahan nilai, visualisasi ini digunakan untuk melengkapi evaluasi kuantitatif yang sebelumnya dilakukan menggunakan metrik MAE, RMSE, MAPE, dan koefisien determinasi (R^2). Visualisasi digunakan untuk mengidentifikasi potensi overfitting pada model yang dikembangkan. Hasil visualisasi ditunjukkan pada gambar berikutnya.



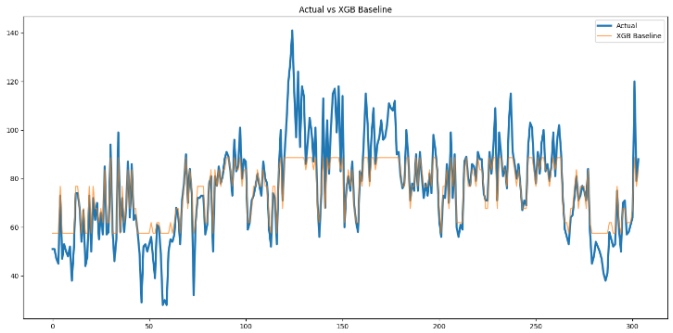
Gambar 5 nilai R^2 pada data *train* dan data *test*

Gambar 2 menunjukkan perbandingan nilai (R^2) antara data *train* dan data *test* pada beberapa model. Perbedaan nilai R^2 yang relatif kecil antara dua data menunjukkan bahwa model tidak mengalami *overfitting* yang signifikan. Selain itu, model yang telah dioptimasi menggunakan *Genetic Algorithm* menunjukkan nilai R^2 yang lebih tinggi dibandingkan model dasar.



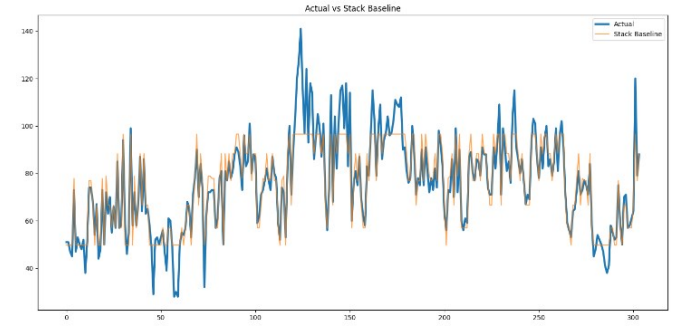
Gambar 2 nilai aktual dengan prediksi *RF Baseline*

Gambar 3 memperlihatkan perbandingan antara nilai aktual ISPU dengan hasil prediksi model *RF* pada konfigurasi *baseline*. Secara umum model mampu mengikuti pola utama perubahan data, namun masih terlihat deviasi pada beberapa periode tertentu. Prediksi model cenderung menghasilkan nilai yang lebih stabil dibandingkan fluktuasi aktual sehingga beberapa lonjakan nilai tidak dapat diikuti secara akurat.



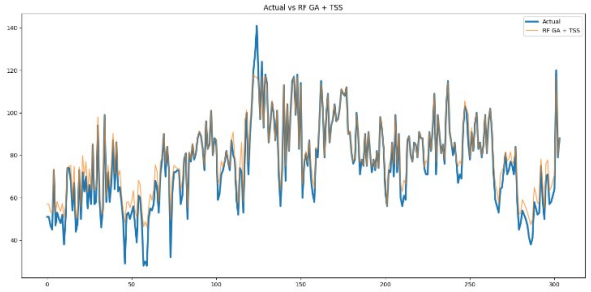
Gambar 3 nilai aktual dengan prediksi XGB *baseline*

Gambar 4 menunjukkan perbandingan antara nilai aktual ISPU dengan hasil prediksi model XGB pada konfigurasi baseline. Secara umum model mampu mengikuti pola perubahan data dengan lebih baik dibandingkan *RF baseline*. Prediksi yang dihasilkan terlihat lebih dekat dengan nilai aktual pada sebagian besar periode pengamatan.



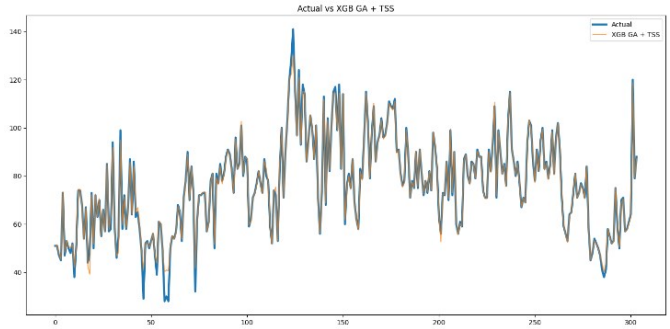
Gambar 4 nilai aktual dengan prediksi *stacking baseline*

Gambar 5 menampikan nilai aktual ISPU dengan hasil prediksi model *stacking* pada konfigurasi baseline. Model *stacking* menggabungkan prediksi dari *RF dan XGB* untuk menghasilkan prediksi akhir yang lebih stabil. Secara umum terlihat bahwa model stacking mampu mengikuti pola perubahan data dengan lebih baik dibandingkan model tunggal pada konfigurasi *baseline*.



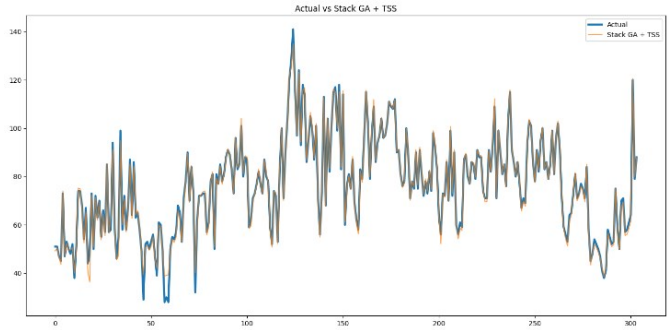
Gambar 6 nilai aktual dengan prediksi *RF* optimasi *Genetic Algorithm*

Gambar 6 memperlihatkan perbandingan antara nilai aktual ISPU dengan hasil prediksi model RF setelah dilakukan optimasi hyperparameter menggunakan *Genetic Algorithm*. Dibandingkan dengan konfigurasi *baseline*, prediksi model terlihat lebih mendekati nilai aktual pada sebagian besar periode pengamatan. Model mampu mengikuti perubahan nilai dengan deviasi yang lebih kecil dibandingkan sebelumnya.



Gambar 7 nilai aktual dengan prediksi *XGB* optimasi *Genetic Algorithm*

Gambar 7 memperlihatkan bahwa garis prediksi model hampir mengikuti pola nilai aktual pada sebagian besar periode pengamatan. Model mampu merepresentasikan fluktuasi data dengan deviasi yang relatif kecil.



Gambar 8 nilai aktual dengan prediksi *stacking* setelah optimasi *Genetic* Algorithm

Gambar 8 menunjukkan perbandingan antara nilai aktual ISPU dengan hasil prediksi model stacking setelah dilakukan optimasi *hyperparameter* menggunakan *Genetic Algorithm*. Terlihat bahwa garis prediksi hampir mengikuti pola nilai aktual pada sebagian besar periode pengamatan.

V. KESIMPULAN

Penelitian ini bertujuan untuk menganalisis kinerja beberapa model pembelajaran mesin dalam memprediksi nilai harian Indeks Standar Pencemar Udara (ISPU) di Kota Jakarta menggunakan pendekatan deret waktu. Model yang digunakan meliputi RF dan XGB sebagai model dasar serta arsitektur *stacking ensemble* dengan *Ridge Regression* sebagai *meta learner*. Hasil evaluasi awal menunjukkan bahwa model tunggal memiliki tingkat akurasi yang berbeda, di mana *RF*menghasilkan performa paling rendah dibandingkan model lainnya.

Penerapan optimasi *hyperparameter* menggunakan *Genetic Algorithm* terbukti memberikan peningkatan performa yang cukup signifikan pada seluruh model yang diuji. Proses optimasi memungkinkan model menemukan konfigurasi parameter yang lebih sesuai dengan karakteristik data deret waktu kualitas udara. Hasil eksperimen menunjukkan bahwa model XGB yang telah dioptimasi menghasilkan nilai kesalahan yang sangat rendah dengan kemampuan prediksi yang sangat baik.

Secara keseluruhan, model terbaik diperoleh pada konfigurasi *stacking ensemble* yang dikombinasikan dengan optimasi *Genetic Algorithm*. Model tersebut mampu menghasilkan nilai RMSE sebesar 1.9802 dan koefisien determinasi (R^2) sebesar 0.9902 yang menunjukkan tingkat akurasi prediksi yang sangat tinggi. Hasil penelitian ini menunjukkan bahwa kombinasi pendekatan *ensemble* dan optimasi *hyperparameter* dapat meningkatkan akurasi serta mempelajari pola kompleks pada data kualitas udara.

REFERENSI

[1] K. Muhamad, L. Puji, D. Oktavia, D. Pratiwi, Y. Uchiyama, and D. Harding, “Towards blue skies : A comprehensive review and regional mapping of ambient air quality in Indonesian cities,” *J. Environ. Manage.*, vol. 389, no. September 2024, p. 126132, 2025, doi: 10.1016/j.jenvman.2025.126132.

[2] A. Fitri, S. Rahman, M. S. Nugraha, and A. Nugraha, “Perancangan dan Monitoring Sistem Pertanian Hidroponik Berbasis Wireless Sensor Network (WSN),” vol. 7, no. 2, pp. 345–349, 2023.

[3] A. Pratama, C. Gudiato, A. Maulana, and W. Prayitno, “Prediksi ISPU Berbasis SVM untuk Masa Depan Jakarta yang Berkelanjutan SVM-Driven ISPU Prediction for Jakarta ’ s Sustainable Future,” vol. 15, no. 1, pp. 66–76, 2025.

[4] M. Kusnandar, “Permen LHK Nomor 14 Tahun 2020,” *Permen LHK Nomor 14 Tahun 2020 Tentang Indeks Standar Pencemar Udar.*, pp. 1–16, 2020, [Online]. Available: https://jdih.menlhk.go.id/new2/uploads/files/P_14_2020_ISPU_menlhk_07302020074834.pdf

[5] D. K. Nurlaili and N. Hendrasarie, “Analisa Kualitas Lingkungan Udara Ambien (PM2 . 5) di Kota Surabaya,” vol. IX, no. 1, pp. 7978–7985, 2024.

[6] Z. Yang, R. Mahendran, P. Yu, R. Xu, W. Yu, and S. Godellawattage, “Health Effects of Long - Term Exposure to Ambient - PM 2 . 5 in Asia - Pacific : a Systematic Review of Cohort Studies,” *Curr. Environ. Heal. Reports*, pp. 130–151, 2022, doi: 10.1007/s40572-022-00344-w.

[7] C. Muluken, E. Di, S. Ferraris, and R. Meo, “Machine Learning with Applications Hyperparameter optimization of machine learning models for predicting actual evapotranspiration,” *Mach. Learn. with Appl.*, vol. 20, no. January, p. 100661, 2025, doi: 10.1016/j.mlwa.2025.100661.

[8] V. Nedungadi *et al.*, “Through Multi-Variable Data Alignment,” 2024.

[9] A. B. Asni, M. W. K, and M. M. Jaya, “Identifikasi Citra Cacat Las Menggunakan Metode Gray Level Co-Occurance Matrix (GLCM) dan

K-NN," vol. 7, no. 1, 2022.
[10] G. Ravindiran, G. Hayder, K. Kanagarathinam, A. Alagumalai, and C. Sonne, "Air quality prediction by machine learning models: A predictive study on the indian coastal city of Visakhapatnam," *Chemosphere*, vol. 338, no. May, p. 139518, 2023, doi: 10.1016/j.chemosphere.2023.139518.
[11] A. Ksibi, A. Salhi, A. S. Alluhaidan, and S. A. El-rahman, "Airstacknet : A Stacking Ensemble-Based Approach for Air Quality Prediction," 2023, doi: 10.32604/cmc.2023.032566.
[12] A. B. Asni and M. W. K, "Penerapan Metode Yolo Object Detection V1 Terhadap Proses Pendeteksian Jenis Kendaraan Di Parkiran," vol. 6, no. 1, 2021.
[13] Z. Xu, H. Zhang, A. Zhai, C. Kong, and J. Zhang, "Stacking Ensemble Learning and SHAP-Based Insights for Urban Air Quality Forecasting: Evidence from Shenyang and Global Implications," *Atmosphere (Basel).*, vol. 16, no. 7, pp. 1–22, 2025, doi: 10.3390/atmos16070776.
[14] T. A. Munshi, K. Popi, L. N. Jahan, M. F. Howladar, and M. Hashan, "Applied Computing and Geosciences Stacking modeling with genetic algorithm-based hyperparameter tuning for uniaxial compressive strength prediction," *Appl. Comput. Geosci.*, vol. 27, no. February, p. 100276, 2025, doi: 10.1016/j.acags.2025.100276.
[15] H. Alibrahim and S. A. Ludwig, "Hyperparameter Optimization : Comparing Genetic Algorithm against Grid Search and Bayesian Optimization".
[16] J. D. S. Kumar, P. Rizwana, M. Pushpanjali, Y. S. Mallika, P. A. Sree, and T. Meghana, "RESEARCH IN ENGINEERING MANAGEMENT AIR QUALITY INDEX FORECASTING VIA GENETIC ALGORITHM BASED IMPROVED EXTREME LEARNING MACHINE," pp. 1784–1790, 2024.
[17] H. Wu, J. Xu, J. Wang, and M. Long, "Autoformer : Decomposition Transformers with Auto-Correlation for Long-Term Series Forecasting," no. NeurIPS, 2021.
[18] U. A. Yakubu, M. Panji, and A. Saputra, "Time Series Model Analysis Using Autocorrelation Function (ACF) and Partial Autocorrelation Function (PACF) for E-wallet Transactions during a Pandemic," vol. 3, no. 3, pp. 80–85, 2022.
[19] A. Abdul, M. Yusoff, W. Fairos, W. Yaacob, and Z. Mustaffa, "MethodsX Repeated time-series cross-validation : A new method to improved COVID-19 forecast accuracy in Malaysia," vol. 13, no. August, 2024, doi: 10.1016/j.mex.2024.103013.
[20] X. Huang *et al.*, "A Hybrid ARIMA-LSTM-XGBoost Model with Linear Regression Stacking for Transformer Oil Temperature Prediction," pp. 1–21, 2025.
[21] T. A. Munshi, K. Popi, L. N. Jahan, M. F. Howladar, and M. Hashan, "Applied Computing and Geosciences Stacking modeling with genetic algorithm-based hyperparameter tuning for uniaxial compressive strength prediction," *Appl. Comput. Geosci.*, vol. 27, no. August, p. 100276, 2025, doi: 10.1016/j.acags.2025.100276.
[22] K. Al-saeedi, D. Zhou, A. Fish, K. Tsakiri, and A. Marsellos, "A Methodological Comparison of Forecasting Models Using KZ Decomposition and Walk-Forward Validation," pp. 1–25, 2025.
[23] M. J. Diamantopoulou and R. Ozçelik, "Evaluation of the random forest regression machine learning technique as an alternative to ecoregional based regression taper modelling," vol. 239, no. August, 2025.
[24] D. Tarwidi, S. Redjeki, D. Adytia, and M. Apri, "MethodsX An optimized XGBoost-based machine learning method for predicting wave run-up on a sloping beach," *MethodsX*, vol. 10, no. December 2022, p. 102119, 2023, doi: 10.1016/j.mex.2023.102119.