Perbandingan Pembagian Data Acak dan Berurutan Waktu pada Klasifikasi Kategori ISPU DKI Jakarta Menggunakan Random Forest dan XGBoost

Proposal Penelitian Data Mining (draf Bab I dan Bab II)

> **Catatan untuk penulis (hapus sebelum dikumpulkan):** Teks dalam kurung siku seperti [sumber] atau [tahun] harus kamu isi atau cek sendiri. Ringkasan penelitian terdahulu di Bab II disusun dari judul, abstrak, dan informasi yang sudah kamu kumpulkan. Baca bagian metode tiap artikel sebelum dikumpulkan, terutama cara pembagian datanya, supaya klaim di Bab II benar.

BAB I. PENDAHULUAN

1.1 Latar Belakang

Pencemaran udara merupakan salah satu masalah lingkungan perkotaan yang berdampak langsung pada kesehatan masyarakat. DKI Jakarta, dengan kepadatan penduduk, volume kendaraan, dan aktivitas industri yang tinggi, termasuk wilayah yang kualitas udaranya terus menjadi perhatian [sumber]. Pemerintah menyampaikan kondisi kualitas udara kepada publik melalui Indeks Standar Pencemar Udara (ISPU). ISPU dihitung dari konsentrasi beberapa parameter pencemar, yaitu PM10, SO2, CO, O3, dan NO2, lalu dikelompokkan ke dalam kategori seperti baik, sedang, tidak sehat, sangat tidak sehat, dan berbahaya [sumber: peraturan ISPU yang berlaku].

Data hasil pemantauan ISPU Jakarta tersedia secara terbuka melalui portal Jakarta Open Data. Ketersediaan data ini mendorong banyak penelitian yang menerapkan algoritma machine learning untuk mengklasifikasikan kategori ISPU, antara lain dengan Random Forest, XGBoost, LightGBM, dan Support Vector Machine. Sebagian penelitian melaporkan akurasi yang sangat tinggi, misalnya akurasi data uji sebesar 99,95% pada penelitian berbasis Random Forest dengan data Jakarta Open Data periode 2016 sampai 2021 (Firdaus dkk., [tahun]).

Akurasi setinggi itu perlu dikaji lebih hati-hati. Pertama, data ISPU adalah data deret waktu, sehingga kondisi udara pada hari-hari yang berdekatan cenderung mirip (autokorelasi). Jika data dibagi secara acak, hari-hari yang bersebelahan dapat terbagi ke data latih dan data uji sekaligus. Model akhirnya diuji pada hari yang kondisi sekitarnya sudah pernah dilihat saat pelatihan. Hal ini dapat membuat akurasi tampak lebih baik daripada kemampuan model yang sebenarnya ketika menghadapi data di masa depan. Kedua, kategori ISPU ditentukan dari nilai parameter pencemar itu sendiri, sehingga klasifikasi kategori dari parameter pada hari yang sama berpotensi menjadi tugas yang terlalu mudah. Kedua dugaan ini perlu diuji secara empiris, bukan hanya diasumsikan.

Beberapa penelitian sudah menggunakan pembagian yang memperhatikan urutan waktu, misalnya TimeSeriesSplit pada prediksi ISPU dengan stacking ensemble dan pembagian berurutan pada model LSTM dan TFT. Namun, berdasarkan penelusuran awal penulis, belum ditemukan penelitian yang secara langsung membandingkan hasil pembagian data acak dan pembagian berurutan waktu pada dataset dan algoritma yang sama untuk klasifikasi ISPU Jakarta [verifikasi ulang setelah membaca semua artikel]. Penelitian ini diusulkan untuk mengisi celah tersebut.

1.2 Urgensi Penelitian

Urgensi penelitian ini mencakup tiga hal.

1. **Keandalan evaluasi.** Model klasifikasi kualitas udara yang akan dipakai untuk peringatan dini harus diuji dengan cara yang mencerminkan kondisi penggunaan nyata, yaitu memprediksi data yang belum pernah dilihat dan berada di masa depan. Evaluasi yang terlalu optimistis dapat menimbulkan kepercayaan berlebih pada model.
2. **Kesenjangan praktik di literatur.** Banyak penelitian klasifikasi ISPU melaporkan akurasi sangat tinggi, tetapi metode pembagian datanya berbeda-beda dan dampaknya jarang dibandingkan secara langsung.
3. **Kebutuhan pedoman metodologis.** Hasil penelitian ini dapat menjadi acuan bagi peneliti lain dalam memilih skema pembagian data untuk data pemantauan lingkungan yang berbentuk deret waktu.

1.3 Rumusan Masalah

1. Bagaimana kinerja Random Forest dan XGBoost dalam mengklasifikasikan kategori ISPU DKI Jakarta ketika data dibagi secara acak?
2. Bagaimana kinerja kedua algoritma tersebut ketika data dibagi secara berurutan waktu (data latih lebih awal, data uji lebih akhir)?

3. Seberapa besar selisih kinerja antara kedua skema pembagian data, dan apa implikasinya terhadap keandalan evaluasi model?
4. Algoritma mana yang lebih stabil terhadap perubahan skema pembagian data?

1.4 Tujuan Penelitian

1. Mengukur kinerja Random Forest dan XGBoost pada klasifikasi kategori ISPU DKI Jakarta dengan pembagian data acak.
2. Mengukur kinerja kedua algoritma dengan pembagian data berurutan waktu.
3. Membandingkan hasil kedua skema untuk menilai ada tidaknya penurunan kinerja yang signifikan ketika urutan waktu diperhatikan.
4. Menentukan algoritma yang lebih stabil terhadap perubahan skema pembagian data.

1.5 Manfaat Penelitian

Manfaat teoretis. Penelitian ini menambah bukti empiris tentang pengaruh skema pembagian data terhadap hasil evaluasi model klasifikasi pada data deret waktu lingkungan, khususnya ISPU.

Manfaat praktis. Hasilnya dapat dipakai peneliti dan pengembang sistem pemantauan kualitas udara sebagai pertimbangan dalam merancang evaluasi model, serta membantu pihak berkepentingan menilai seberapa dapat diandalkan klaim akurasi pada model klasifikasi ISPU.

1.6 Ruang Lingkup dan Batasan

Penelitian ini dibatasi pada data ISPU DKI Jakarta dari portal Jakarta Open Data untuk periode [tentukan periode setelah dataset dipilih]. Algoritma yang dibandingkan adalah Random Forest dan XGBoost, dengan [Decision Tree sebagai baseline, jika dipakai]. Variabel target adalah kategori ISPU. Penelitian ini berfokus pada pengaruh skema pembagian data, bukan pada optimasi hiperparameter secara mendalam.

BAB II. STUDI LITERATUR

2.1 Penelitian Terdahulu

Berikut penelitian terdahulu yang relevan, dikelompokkan berdasarkan fokusnya.

a. Klasifikasi ISPU dengan pembagian data acak atau stratified

Firdaus dkk. ([tahun]) menerapkan Random Forest untuk klasifikasi pencemaran udara wilayah Jakarta menggunakan data Jakarta Open Data periode 2016 sampai 2021. Model mencapai akurasi 100% pada data latih dan 99,95% pada data uji. Akurasi yang hampir sempurna ini menunjukkan bahwa tugas klasifikasi tersebut sangat mudah bagi model, tetapi artikel tersebut belum dibaca dari sisi metode pembagian datanya [cek bagian metode].

Penelitian di Jurnal JUSTINDO ([penulis], [tahun]) membandingkan Random Forest, Support Vector Machine, dan LightGBM pada klasifikasi kualitas udara di Jakarta. Random Forest menghasilkan akurasi tertinggi, yaitu 98%. Penelitian lain pada ISPU DKI Jakarta tahun 2021 menggunakan Random Forest dengan pembagian stratified ([penulis], [tahun], JTIUST). Pembagian stratified menjaga proporsi kelas, tetapi tetap tidak memperhatikan urutan waktu [cek].

b. Klasifikasi ISPU dengan algoritma boosting dan penanganan ketidakseimbangan kelas

Swesty dkk. ([tahun]) mengklasifikasikan ISPU harian DKI Jakarta berdasarkan parameter polutan gas menggunakan Random Forest dan XGBoost, yaitu dua algoritma yang juga digunakan dalam penelitian ini. Penelitian pada Jurnal ITG ([penulis], [tahun]) menggunakan CatBoost dengan Random UnderSampling untuk menangani ketidakseimbangan kelas pada klasifikasi ISPU. Junaidi (2024) menerapkan XGBoost dengan SMOTE pada klasifikasi ISPU. Ketiganya menunjukkan bahwa ketidakseimbangan kelas adalah masalah yang umum pada data ISPU, karena kategori baik dan sedang jauh lebih sering muncul daripada kategori tidak sehat [cek proporsi kelas pada dataset sendiri].

c. Penelitian yang memperhatikan urutan waktu

Penelitian tentang prediksi dan klasifikasi kualitas udara DKI Jakarta dengan LSTM dan Temporal Fusion Transformer ([penulis], [tahun]) menggunakan pembagian data yang berurutan waktu. Penelitian prediksi ISPU dengan stacking ensemble dan Genetic Algorithm ([penulis], [tahun]) menggunakan TimeSeriesSplit. Kedua penelitian ini menunjukkan bahwa pembagian yang sadar waktu sudah dikenal di literatur ISPU, tetapi penekanannya pada pengembangan model, bukan pada perbandingan dengan pembagian acak [cek setelah dibaca].

d. Penelitian dengan algoritma lain pada data ISPU

Suhendi dkk. ([tahun]) menerapkan beberapa algoritma machine learning untuk klasifikasi polusi udara DKI Jakarta dengan data tahun 2024. Penelitian pada SNATIF 2025 ([penulis]) menggunakan LightGBM berdasarkan ISPU dengan data tahun 2024.

Penelitian di Politeknik Penerbangan Surabaya ([penulis], 2024) menggunakan Support Vector Machine. Penelitian-penelitian ini memperlihatkan keragaman algoritma yang dipakai, sementara pembahasan tentang cara pembagian data relatif terbatas [cek].

2.2 Celah Penelitian (Research Gap)

Dari telaah di atas, celah penelitian dapat dirumuskan sebagai berikut.

1. Banyak penelitian klasifikasi ISPU Jakarta melaporkan akurasi sangat tinggi (98% sampai 99,95%) dengan pembagian data acak atau stratified, tanpa membahas kemungkinan bahwa autokorelasi waktu membuat evaluasi terlalu optimistis.
2. Penelitian yang memakai pembagian berurutan waktu (LSTM dan TFT, TimeSeriesSplit) berfokus pada pengembangan model, bukan membandingkan secara langsung dengan pembagian acak pada data dan algoritma yang sama.
3. Belum tampak perbandingan terkontrol antara Random Forest dan XGBoost terhadap perubahan skema pembagian data untuk klasifikasi kategori ISPU Jakarta [verifikasi setelah semua artikel dibaca].

2.3 Kontribusi Penelitian yang Diusulkan

Penelitian ini menawarkan tiga kontribusi dibandingkan penelitian sebelumnya.

1. **Perbandingan terkontrol.** Dataset, fitur, algoritma, dan metrik dibuat sama, dan hanya skema pembagian data (acak vs berurutan waktu) yang diubah, sehingga selisih kinerja dapat dikaitkan langsung dengan skema tersebut.
2. **Pengujian kestabilan algoritma.** Random Forest dan XGBoost dibandingkan dari sisi seberapa besar kinerjanya berubah ketika skema pembagian data berubah.
3. **Rekomendasi metodologis.** Hasil penelitian dirumuskan menjadi saran praktis skema evaluasi yang lebih realistis untuk klasifikasi kualitas udara berbasis data deret waktu.